

제형 독성 예측 모델

데이터 현황 · 진척 보고 및 향후 모델 개발 방향

눈 자극·손상 (GHS 3.3) · 피부 부식·자극 (3.2) · 피부 감작 (3.4)

항목	내용
작성 기준일	2026-08-20
대상 데이터	제형 1,675 건 · 성분 5,287 행
모델 입력	out/v2/ (X_formulation 1,675 × 518)
사람 열람용	input_dataset_v2.xlsx (8 시트) — 초안, 계속 업데이트 예정
근거 문서	README.md · LIMITATIONS.md · DESCRIPTOR_DESIGN.md · MEETING_REPORT.md
다음 주 분담	SDS Section 9 (pH) 수집 = 팀 / 데이터 정리·모델링 = 단독

0. 요약

구분	지표	현재	판정
규모	제형 / 성분 행	1,675 / 5,287	확정
라벨	타깃 보유 제형	1,525 (91.0%)	학습 착수 가능
라벨	눈 / 피부 / 감작	1,105 / 992 / 595	감작이 최소
라벨	음성(NC) 확보	379 / 614 / 209	이번 주 최대 성과
학습	Track A 학습 가능	1,345 행	가능
학습	Track B 학습 가능	652 행	제한적
구조	CT 가산식 산출 제형	719 (42.9%)	성분 GHS 결측이 병목
물성	pH 보유	533 (31.8%)	그중 286 행이 제품값 아님
누출	$X \cap \text{label_source}$	0	차단 확인
성능	순서형 macro-F1 (눈/피부/감작)	0.499 / 0.507 / 0.677	더미 대비 1.7~3.9 배
성능	Track B 잔차부호 (눈/피부)	0.628 / 0.618	핵심 가설 유효

이번 보고의 핵심 세 가지

- ① **데이터:** 웹 접근 0 회로 라벨을 대량 확보. SDS Section 11 자유서술문을 규칙 기반으로 재파싱해 눈 +150 · 피부 +137 · 감작 +184 행을 회수하고, 특히 음성 라벨이 감작에서 50 → 209 행으로 증가. 감작 양성률 87.8% → 64.9%.
- ② **가설:** GHS 농도가산식(CT)이 언제 틀리는지를 상호작용 피쳐로 예측 가능(잔차 부호 3 클래스 0.628, 우연 0.33). 그리고 CT 는 눈에서 47%를 과소예측. 이 비대칭이 논문의 주장.
- ③ **병목:** 모델이 아니라 데이터. 다만 남은 결측 중 상당 부분이 이미 보유한 파일만으로 해소 가능하며 (SDS §11 원문 미판독 308 / 320 / 327 행), 외부 수집이 반드시 필요한 항목은 pH 로 좁혀짐.

이 문서의 성능 수치는 전부 튜닝 전 · 리샘플링 전 · 지문 미적용 상태의 스모크 베이스라인. 상한이 아니라 하한으로 읽을 것.


1. 데이터 현황

1.1 전체 규모와 구성

단위	행 수	피쳐 수	파일	설명
제형	1,675	518	X_formulation.parquet	농도가중 모멘트 + 상호작용 항 + 실측 물성 + CT baseline + SDS §11 수치
성분	5,287	174	X_ingredient.parquet	RDKit 디스크립터 31 종 + 구조경보 24 종 + 역할 + 계면활성제 전하클래스
타깃	1,675	35	y_formulation.parquet	엔드포인트별 원본 · 순서형 · 이진 · 출처 · 충돌 플래그 · Track B 잔차
CV 키	1,675	1	groups.parquet	주성분 CAS 기준 664 그룹 (최대 46 행)
지문	5,287	2,048 / 167	fp_ing_*.npz	Morgan(ECFP4) · MACCS
지문	1,675	4,096 / 334	fp_form_pooled.npz	제형 단위 [max 농도가중 mean] pooling
사전	1,070	8	feature_manifest.csv	role = feature 442 / feature_derived 345 / label_source 228 / provenance 47 / id 8

1.2 라벨 확보 현황

그림 1. 엔드포인트별 라벨 확보 현황 — 양성 / 음성 / 미확보



↑ 감작은 라벨 595 행(35.5%)으로 세 축 중 최소. 음성(NC)은 "자극 없음이 확인된 제품".


제형 1,675 건 중 **1,525 건(91.0%)**이 최소 하나의 엔드포인트에 라벨을 보유. 나머지 150 건은 어떤 엔드포인트에도 라벨이 없어 학습에는 미사용하고 예측 대상으로만 활용.

음성 라벨의 의미 — 표에서 NC(Not Classified, 분류 대상 아님)로 표기한 행은 "자극이 없음이 확인된 제품". 이 값이 없으면 모델이 모든 제품을 위험하다고 답해도 점수가 유지되므로, 음성 표본 확보가 양성 확보보다 우선순위가 높음.

1.3 이번 주 진척 — SDS Section 11 재파싱 (F0.5)

독성코드 수집 하네스는 SDS 에서 15 개 파라미터를 회수했으나, 시트 기입 단계에서 신호어와 H 코드 2 개만 기록하고 나머지 13 개는 반영되지 않은 상태였음. 원본 수집 결과 파일(final_merged_results.json)에는 전량 보존되어 있어, 이를 규칙 기반으로 재파싱해 라벨과 수치 피쳐로 편입. **웹 접근 0 회 · 추가 수집 인력 0 명.**

그림 2. SDS Section 11 서술문 재파싱(F0.5) 효과 — 웹 접근 0회



↑ 왼쪽은 전체 라벨, 오른쪽은 음성(NC) 라벨. 감작 음성 50 → 209 행 증가가 최대 성과.


항목	이전	이후	증감
눈 라벨	955	1,105	+150
피부 라벨	855	992	+137
감작 라벨	411	595	+184
눈 음성(NC)	266	379	+113
피부 음성(NC)	493	614	+121
감작 음성(NC)	50	209	+159

Track B 잔차 타겟 (눈/피부/감작)	412 / 339 / 117	456 / 382 / 184	+44 / +43 / +67
경구 LD50 (신규 수치 피쳐)	0	617 행	신규
경피 LD50 / 흡입 LC50	0 / 0	531 / 392 행	신규
발암·변이원·생식·STOT·흡인 순서형	0	149 / 101 / 101 / 117 / 103 / 99	신규

대가도 함께 기록 — 라벨 충돌이 눈 69→124 · 피부 67→88 · 감작 1→10 으로 증가하고, 현재 라벨의 13.6%(눈) / 13.8%(피부) / 30.9%(감작)가 정규식으로 파싱한 자유서술. 신규 수치 피쳐의 성능 기여는 사실상 0(ablation Δ = +0.001~+0.040)이며, **F0.5 의 이득은 피쳐가 아니라 라벨에서 발생.**

1.4 항목별 확보율

그림 5. 항목별 데이터 확보율 — 위 7개는 제형(1,675) 기준, 아래 3개는 성분 행(5,287) 기준



↑ 점선은 60% 기준선. 확보율이 낮은 세 항목(성분 GHS · pH · 감작 라벨)이 그대로 병목.

확보율이 가장 낮은 세 항목이 그대로 병목. **성분 GHS 구분 21.5%** → CT 가산식 산출률 제약, **pH 31.8%** → CT 예외 게이트 사용 불가, **감작 라벨 35.5%** → 감작 Track B 표본 부족.

2. 데이터 품질 — 알려진 결함과 한계

2.1 라벨의 성격 — 예측 대상이 무엇인가

현재 라벨은 대부분 "GHS 분류 결과"이며 "생체 독성 반응" 자체가 아님. NTP 실측(눈 608 · 피부 544)을 제외한 나머지는 SDS 의 H 코드·신호어·서술문에서 유도. 감작 라벨 595 건은 실측값 0 건으로 전부 H317/서술문 유도. 논문에서는 이 구분을 Limitations 절에 명시할 필요.

라벨 출처 tier는 다섯 단계이며 위가 우선. 하위 tier가 상위 tier를 덮지 않으므로 신규 라벨만 추가되고 기존 값은 불변.

우선	출처	눈	피부	감작	성격
1	ntp_measured	608	544	—	NTP 실측 시험값
2	sds_v1	181	157	—	v1 SDS H 코드
3	sds_2nd	135	123	198	2 차 수집 H 코드·신호어
4	phase1_sds	31	31	29	Phase 1 에이전트 회수
5	sds_2nd_sec11	150	137	184	F0.5 — Section 11 자유서술 (최하위)

2.2 확인된 결함 3 개

#	결함	실측	영향	해소 경로
1	특성 시트 pH 의 제품값 여부가 분리되지 않음	메모 469 건이 "제품 값 아님" 명시 · pH 830 행 중 286 행 해당	CT 예외 게이트($\text{pH} \leq 2 / \geq 11.5$)가 활성성분 원제 pH 를 제품 pH 로 취급해 오작동 중	메모 텍스트 파싱 → 별도 열 신설. 단독 · 반나절
2	라벨 충돌 미판정	눈 124 · 피부 88 · 감작 10 = 222 건	출처 간 값이 달라 어느 쪽이 정답인지 미확정. 성능 상한을 제약	티어 우선순위 자동 해소 + 잔여 육안 판정. 단독
3	감작성 실측값 0 건	라벨 595 건 전부 H317·서술문 유도	"SDS 기재 내용 예측"과 "실제 감작성 예측"의 차이. 심사에서 지적 예상	LLNA / DPRA / h-CLAT 외부 DB 필요 — 현 조건에서 해소 불가


2.3 구조적 한계 (해소 불가, 논문에 명시)

- **제형 표현의 축약:** 제형을 성분 목록과 농도로만 표현. 미셀 크기·액적 분포·상 거동·제조 공정은 SDS 에 부재.
- **노출 시나리오 혼재:** GHS 구분은 원액 기준이나 일부 제품은 희석 사용이 전제. 희석배수 정보 없음.
- **시간 축 부재:** SDS 개정판마다 분류가 변경되는데 개정일을 컬럼으로 확보하지 못함.
- **구조 미확보 32.4%:** 성분 5,287 행 중 3,574 행(67.6%)만 SMILES 확보. 미확보 1,713 행 중 로컬 회수 가능분은 동일 CAS 16 + 동일명 41 = 57 행(3.3%)뿐.
- **active 플래그 부재:** 그룹 분할 키가 주성분 CAS 기준이며 성분별 active 플래그가 없어, 활성성분 판정이 농도 순위 기반 대리지표에 의존.

3. 모델 구조와 현재 성능

3.1 2 층 디스크립터와 Track A / Track B

그림 7. 2층 디스크립터와 Track A / Track B 구조



↑ 성분 블록을 제형 블록으로 집계하고, 가산 성분(①)과 비가산 성분(②)을 분리해 두 Track 에 다르게 투입하는 구조.


성분 층과 제형 층을 분리한 이유 두 가지. ① **해석 가능성** — 모델이 "logP 가 높아서"라고 답할 때 어느 성분의 logP 인지 특정되지 않으면 제형 설계에 활용 불가. ② **CT와의 접점** — GHS 가산식은 정의상 Σ(성분 구분 × 성분 농도)이므로, 성분 단위 표현이 없으면 Track B 구성 자체가 불가.

Track A (직접 예측) — 입력은 농도가중 모멘트 + 상호작용 항 + 실측 물성 + 지문. 학습 가능 1,345 행. 타겟은 순서형(y_*_ord)과 이진(y_*_bin).

Track B (CT 잔차 보정) — 타겟은 resid = 실제 순서형 - CT 예측 순서형. 학습 가능 652 행. 입력은 상호작용 항과 예외 게이트, CT 합계로 **한정** — 가산 항은 이미 CT 가 설명하므로 재투입하면 표본 효율이 떨어짐.

3.2 CT 가산식은 어느 방향으로 틀리는가

그림 3. GHS 농도가산식(CT)의 오차 방향 — Track B 의 근거




↑ 라벨과 CT 예측이 모두 존재하는 행의 잔차 방향. 눈에서 47%가 과소예측(실제가 CT 보다 심함).

눈에서 **213/456 (47%)**가 과소예측이고 적중은 42%. 피부는 CT 가 68%를 적중. 이 비대칭이 "상호작용을 반영하지 않은 결과"에 해당하는 잔차이며 Track B 가 포착해야 할 신호. 감작은 음성 표본 확보 후 과대예측이 0 → 10 건 발생해 실질 2 클래스에서 3 클래스 과제로 전환.

3.3 베이스라인 성능

그림 4. 베이스라인 성능 — 더미 대비로 읽어야 하는 이유 (튜닝·리샘플링·지문 미적용)



↑ RandomForest 300trees · StratifiedGroupKFold(5) · class_weight=balanced. 하단 Δ 는 모델 F1 – 더미 F1.

F1 절대값만 보면 해석이 역전됨. F0.5 이전 눈 이진 F1 은 0.832, 현재는 0.798 로 하락. 단, 같은 구간에서 더미가 0.838 → 0.793 으로 더 크게 하락했고 balAcc 은 0.593 → 0.624 로 상승. 음성 라벨 유입으로 과제 난이도가 정상화된 결과이며 모델 성능 저하가 아님. → 성능은 "더미 대비 + balAcc" 로만 판단할 것.

과제	n	F1	balAcc	더미 F1	판정
눈 이진	1,105	0.798 ± 0.022	0.624	0.793	더미 근소 초과 (+0.005)
눈 순서형	1,105	0.499 ± 0.042	0.496	0.128	신호 있음 (더미 3.9 배)
피부 이진	992	0.679 ± 0.045	0.752	0.000	신호 있음
피부 순서형	992	0.507 ± 0.040	0.494	0.191	신호 있음 (더미 2.7 배)
감작 이진	595	0.808 ± 0.027	0.670	0.787	더미 근소 초과 (+0.021)
감작 순서형	595	0.677 ± 0.040	0.670	0.393	신호 있음
Track B 눈 잔차부호	456	0.628 (macro)	—	~0.33	가설 유효
Track B 피부 잔차부호	382	0.618 (macro)	—	~0.33	가설 유효
Track B 감작 잔차부호	184	0.417 (macro)	—	~0.33	보고 금지 (소수클래스)

					10 행)
--	--	--	--	--	-------


- Track B(0.628 / 0.618)가 Track A 순서형(0.499 / 0.507)보다 적중률이 높음. 동일 피처로 절대 구분보다 CT 오차 예측이 더 용이하다는 의미이며, 잔차 보정 접근의 근거.
- 소수점 둘째 자리는 신뢰하지 말 것. 성분 GHS 레코드 1 건만 증가한 재빌드에서 순서형이 0.475 → 0.495로 변동한 전례가 있음. 순서형 점수는 ± 0.03 수준의 불안정성을 가지므로 최종 수치는 반복 CV 평균으로 보고.
- 누출 차단은 검증 완료 — label_source 228 열을 X에서 물리적으로 제외하고 교집합 0 확인. sds_coderived 54 열은 사용 가능하나 논문에는 이 열을 뺀 ablation을 함께 보고할 필요.

4. 남은 데이터 회수 여지

남은 결측을 "이미 보유한 파일로 해소 가능한 것"과 "외부 접근이 필요한 것"으로 실측 분리.

4.1 웹 접근 없이 가능 — SDS Section 11 원문 2 차 판독

그림 6. 남은 회수 여지 — 수집은 끝났고 판독이 남은 구간



↑ 왼쪽은 §11 원문 보유 행의 판독 상태, 오른쪽은 미판독 행 중 최종 라벨이 없는 행을 전량 회수했을 때의 상한.

엔드포인트	원문 보유	추출 성공	미추출	그중 라벨 부재	현재 → 상한
눈	874	566	308	163	1,105 → 1,268
피부	801	481	320	190	992 → 1,182
감작	788	461	327	278	595 → 873 (+47%)

미추출 사유는 대부분 정성 서술만 존재하거나 표현 변형으로 규칙에 미포착된 경우. 규칙 5 원칙(결측/음성 구분 · 정성서술 승격 금지 · EPA↔GHS · 엔드포인트 교차오염 차단 · 단위 없는 값 폐기)을 유지한 상태로 규칙을 확장하고 잔여는 육안 판독. **감작 Track B의 소수클래스 10행 문제는 이 경로로만 해소 가능.**

4.2 웹 접근 없이 가능 — 나머지

작업	실측 규모	효과
특성 시트 제품값여부 열 분리	pH 830 행 중 286 행	CT 예외 게이트 정상화
라벨 충돌 판정	222 건 (124 / 88 / 10)	출처 신뢰도 순위 근거 확보
t11_*_ambig 확인	99 건 (62 / 19 / 18)	민감도 분석용 제외군 확정

모델링 전체	—	반복 CV · 누적 이진 · 지문 · SHAP · 라우팅
--------	---	---------------------------------

4.3 외부 접근이 필요 — 닫힌 경로

항목	왜 단독 불가	처리 방침
제품 SDS Section 9 (pH)	제품 단위 실측값이라 구조·성분에서 유도 불가. 체계적 수집 이력 0	★ 팀에 요청 (분담)
성분 GHS 구분 1,963 행	PubChem PUG-View / ECHA C&L 접근 필요. 동일 CAS 전역 재사용(871)과 이름 매칭(144)은 이미 소진	한계로 기록. CT 산출 719 유지
감작성 실측값	LLNA / DPRA / h-CLAT 외부 DB. 라이선스 문제로 인력 배정으로 해결되지 않음	논문 Limitations 에 명시
백로그 P2 460 행 / P4 298 행	일부 제품은 SDS 가 원리적으로 부재(단종·규제금지·개발코드·NTP 조제 혼합물). 회수율 낮음	배치 파일 보존, 목표에서 제외
SMILES 미확보 1,713 행	로컬 회수 가능분 57 행(3.3%)뿐	한계로 기록
검증 워크플로 4 종 실행	웹 접근 필요. 신뢰도 low 277 + medium 408 재확인 대상	미실행 상태 명시 유지

확인 결과 닫힌 경로 2 건: formulation_harness/_run/ 에는 미반영 1 차 수집 결과가 없고 (row_mapping.json + unique_products.json 만 존재), 성분 함량 텍스트 2,053 행은 파싱 100% 성공이라 재파싱 여유분이 0. CT 산출물의 병목은 함량이 아니라 성분 GHS 구분 — 함량은 있는데 GHS 가 없는 성분 행이 1,963 개.

5. 향후 모델 개발 방향

5.1 1 단계 — 성능 수치를 신뢰 가능하게 만들기

현재 상태의 문제는 성능이 낮은 것이 아니라 **성능을 비교할 수 없는 것**. 순서형 점수가 ± 0.03 흔들리므로 개선과 노이즈의 구분이 불가. 이 단계를 먼저 완료해야 이후 모든 실험이 의미를 가짐.

#	작업	구체 내용	판단 기준
1	반복 CV 전환	5×5 repeated StratifiedGroupKFold 로 평균 $\pm$ 표준편차 산출. groups.parquet(664 그룹) 필수	표준편차가 개선폭보다 작아야 보고 가능
2	순서형 정식 구현	현재 다중분류 → 누적 이진분류 스택 $P(\geq 2B) \cdot P(\geq 2A) \cdot P(=1)$ 로 전환	순서 관계 위반율 감소 + macro-F1 상승
3	지문 투입	fp_form_pooled.npz 를 스모크에 편입. MACCS(해석 가능·선행연구 비교군) 먼저, Morgan 은 비교군	더미 대비 마진 확대
4	불균형 대응	class_weight='balanced' → SMOTE → SMOTEENN 순 비교. 리샘플링은 CV 폴드 내부에서만	balAcc 개선 + 폴드 간 분산 감소
5	임계값 튜닝	F1 / Youden J 기준 폴드별 최적화. 기본 0.5 는 불균형에서 무의미	이진 과제의 더미 초과 마진

5.2 2 단계 — 가설 검증과 해석

- **Track B SHAP 분석:** 성능 숫자보다 이 연구의 실질적 산출물. "계면활성제 전하쌍(f_surf_charge_pair)이나 용매 $\times$ logP(f_solvent_x_logp) 항이 실제로 CT 오차를 설명하는가"를 확인. 설명된다면 논문의 주장이 성립하고, 설명되지 않는다면 상호작용 항 설계를 재검토.
- **커버리지 기반 앙상블 라우팅:** f_ct_*_coverage 로 게이팅. 커버리지가 높은 행은 Track B 가중을 상향하고, 구조는 있으나 성분 GHS 가 없는 행은 Track A 로 이관. 단순 평균보다 이 데이터의 결측 구조에 적합.
- **ablation 표 작성:** sds_coderived 54 열을 제외한 성능을 함께 보고. 라벨과 같은 SDS 문서에서 나온 피쳐이므로 동일문서 상관 가능성을 배제해야 심사에서 방어 가능.
- **민감도 분석:** t11_*_ambig 99 건과 t11_*_weak_nc 50 건을 제외하고 성능이 유지되는지 확인. 유지되지 않으면 해당 라벨 처리 방식을 재검토.

5.3 3 단계 — 논문용 실험 설계

실험	목적	구성
데이터 기여 곡선	"데이터를 늘리면 성능이"	라벨 수를 25/50/75/100%로 증화 subsample 하고 축별(\$11

	오르는가"를 정량화	판독분 · pH 반영분) 재빌드 성능 비교
Track A vs Track B vs 양상블	잔차 보정 접근의 우위 입증	동일 폴드·동일 피처에서 세 방식 비교. 커버리지 구간별로 분리 보고
CT 단독 baseline	규제 표준 대비 개선폭 제시	가산식만 사용한 예측을 baseline 으로 두고 모델의 추가 이득을 측정
선행연구 비교군	docx 가 인용한 MACCS+SMOTE 조합 재현	동일 지표로 비교해 본 연구의 상대 위치 제시
기전 해석	예측 근거가 화학적으로 타당한지 확인	SHAP 상위 피처를 알려진 기전(각질층 투과 · 단백질 변성 · KE1 반응성)과 대조


5.4 하지 말 것

- ✗ 성분 SDS 를 사람이 합성해 제품 GHS 분류를 생성·기입 — Track B 의 타깃이 오염됨
- ✗ EPA Tox Category(I~IV) ↔ GHS 구분 환산 — 컷오프가 다른 별개 체계
- ✗ 정성 서술("중등도 자극성")을 구분 숫자로 승격 — 구분을 특정하지 않는 진술
- ✗ 리샘플링을 CV 폴드 밖에서 수행 — 누출
- ✗ groups.parquet 없이 CV — 같은 활성성분 제형이 갈리면 성능 과대평가
- ✗ input_dataset_v2.xlsx 를 모델에 직접 투입 — 라벨 유도 컬럼 228 개 포함
- ✗ 감작 Track B 점수(0.417) 보고 — 소수클래스 10 행 규모의 3 클래스 전환 인공물
- ✗ F1 단독 판단 — 더미 대비와 balAcc 을 함께 볼 것

6. 다음 주 진행 — 분담과 일정

데이터 수집 인력 배분 없음을 전제로 재구성. 데이터 정리·추가 추출·모델링은 한서윤이 진행하고, 단독으로 대체 불가능한 **SDS Section 9 (pH)** 수집을 팀에 요청.

그림 8. 다음 주 작업 배분 — 데이터 정리·모델링은 단독, Section 9 는 팀



↑ 파란색은 단독, 빨간색은 팀, 녹색은 공동. 데이터 정리와 모델링을 병행하고 금요일에 통합 재빌드.

6.1 단독 진행 항목

순위	작업	산출물	규모
1	SDS §11 원문 2 차 판독	라벨 증가 (감작 최우선)	3 일
2	특성 시트 제품값여부 열 분리	pc2_ph_is_product 열 + ct_not_applicable 재산출	반나절
3	라벨 충돌 222 건 판정	충돌 판정표 + 출처 신뢰도 순위	1.5 일
4	반복 CV 전환 · 누적 이진 스택	smoke_report_v3.json	2 일
5	지문 투입 · Track B SHAP · 라우팅	SHAP 그림 + 논문용 성능표 1 장	2 일
6	input_dataset 초안 갱신	input_dataset_v3.xlsx + out/v3/	재빌드 시 자동

6.2 팀 요청 — SDS Section 9 (pH)

pH 만 요청하는 근거 세 가지 — ① 모델 구조에 직결: 라벨 품질이 아니라 CT 가산식의 적용 가능 여부를 결정하는 게이트. 현재 강산 4 건 · 강염기 8 건 · CT 예외 총 23 건만 식별된 상태이고 실제 예외 제형은 더 많을 것으로 추정. ② 로컬 유도 불가: 제품 단위 실측값이라 구조·성분에서 계산 경로가 없음. ③ 분담 효율 최고: SDS 한 섹션의 숫자

하나여서 화학 지식 없이도 수집 가능.

항목	내용
대상	제품 SDS Section 9 (물리화학적 성질) 의 pH 값
우선순위	제형코드 SL / SC / EC (액상) 부터 — 액상은 pH 기재율이 높고 고체는 누락이 잦음
필수	근거 URL. 못 찾으면 비우고 메모에 [SDS 없음] 또는 [접근차단]
함께 기록	희석 조건 (예: "1% 수용액 pH 6.5") — 원액 pH 와 다른 값
삭제 금지	값의 조건 표기(at 25 C)와 estimated 표기
금지	추정값 생성. 비우고 사유를 메모하는 쪽이 항상 우선
목표	pH 제품값 유효행 약 247 → 400 이상
미요청	기존 830 행의 제품값 여부 판별은 단독 처리하므로 신규 수집만 담당

메모 태그 규칙 — 자유서술 메모는 파싱 오차가 발생하므로 앞에 대괄호 태그를 부착. [SDS 없음] [접근차단] [성분불일치] [대체:성분 SDS] [대체:라벨] [제품값아님] [구형 MSDS] [EPA 체계] [부분] [추정:제품명]. 예) [대체:성분 SDS][제품값아님] 활성성분 Beta-Cyfluthrin 원제 물성. 제품 SDS 미확인

참고로 특성 시트 메모는 4 시트 중 품질이 가장 높았음 — 메모 976 건 중 63.6%가 "활성성분 원제 물성", 48.1%가 "제품 값 아님"을 명시하고 있어 이 값들을 제품 물성으로 잘못 사용하는 상황을 방지. pH 수집도 같은 수준으로 유지하면 충분.

6.3 다음 주 확인 지표

지표	현재	목표	담당
감작 라벨	595	750 이상	단독
눈 라벨	1,105	1,200 이상	단독
라벨 충돌 미판정	222	0	단독
pH 제품값 확정 플래그	미분리	분리 완료	단독
순서형 성능 (반복 CV)	미측정	측정 완료 + 표 1 장	단독
pH 유효값 (제품값)	약 247	400 이상	팀
CT 산출 제형	719	유지 (개선 불가)	—

7. 산출물과 업데이트 계획

7.1 모델용 데이터와 사람용 데이터의 분리

구분	파일	용도	주의
모델용	out/v2/*.parquet + *.npz	학습·평가에 사용하는 본체	label_source 228 열은 이미 제외됨
사람용	input_dataset_v2.xlsx (8 시트)	눈으로 검토·공유·출처 추적	모델에 직접 투입 금지 — 라벨 유도 컬럼 포함
팀 반환용	dataset_2 차배정_verified.xlsx	검증여부·검증근거·검증방식 기입본	원본 dataset_2 차배정.xlsx 는 미수정

사람용 파일의 provenance 시트(4,552 행)가 어느 값이 어디서 왔는지를 보관하므로, 값에 의문이 생기면 이 시트에서 역추적 가능.

7.2 input_dataset 갱신 절차

현재 input_dataset_v2.xlsx 는 초안이며 데이터 정리가 진행되는 동안 계속 갱신 예정. 빌더는 먹등하므로 재실행 시 같은 입력에서 같은 결과를 산출.

1. 2 차 시트 갱신 (§11 판독 결과 · 제품값여부 열 · 총돌 판정 반영)
2. python3 work/verify_sheets.py — 검증란 규칙 엔진 재실행
3. python3 work/build_input_v2.py — out/v2/ 와 input_dataset_v2.xlsx 전량 재생성 (5~10 분)
4. python3 work/smoke_baseline.py — 누출 점검 + 베이스라인
5. 누출 점검값 $X \cap \text{label_source} = 0$ 확인. 0 이 아니면 즉시 중단
6. 변경 전후 지표를 축별로 기록 — 어느 축이 성능을 움직였는지 추적 가능하게 유지

원본 2 개(dataset_2 차배정.xlsx, input_dataset.xlsx)는 이번 작업에서 한 번도 수정하지 않았고, 모든 산출물은 새 파일로 생성. 재현성과 되돌리기의 근거이므로 이 규칙을 유지.

7.3 축을 하나씩 투입하는 이유

수집과 재빌드를 분리하고 축을 하나씩 넣어 재빌드하면 "감작 라벨 155 건 추가로 balAcc 이 얼마 상승", "pH 150 건 추가로 CT 예외 게이트가 몇 건 변경" 을 제시할 수 있음. 이 내용이 논문의 데이터 기여 섹션이 되며, 동시에 예상과 다른 결과가 나올 때 원인 축을 특정하는 수단이 됨.