

제형 특성 추출 파이프라인 사용 설명서

Formulation Characteristics Extraction Pipeline

2026-07-13 (v1.1 — Phase 1.5 Pre-fill Merge 추가)

1. 개요 (Overview)

이 v1 워크플로우는 1,675 개의 제형(Formulation) 데이터에서 5 가지 핵심 특성을 자동으로 추출하는 python script 기반 파이프라인입니다. (이후 v2, v3 보완 예정.)

추출 대상 5 가지 차원

에이전트	차원	주요 출력 필드	활용
A1	제형 타입	formulation_code, physical_form, product_category	EC/SC/WP 등 제형 형태 분류
A2	위험도 프로파일	signal_word, h_codes, hazard_level_score (0-5)	GHS 위험 등급 자동 추출
A3	사용 목적	use_class, target_pest_organism, application_method	농약/연구용/독성연구 분류
A4	규제 정보	epa_reg_number, regulatory_jurisdiction, registration_status	EPA 등록번호 등
A5	성분 프로파일	active_pct_total, formulation_complexity_score (1-5)	활성성분 비율 및 복잡도

2. 데이터 현황

항목	값	비고
전체 제형 수	1,675 개	마스터 워크북 기준
Cancer_PID 계열	17 개	규칙 기반 처리 (LLM 미사용)
LLM 추출 대상	1,658 개	50 행 배치 × 34 회
PDF 파싱 완료	411 개 JSON	section_extracts/ 포함됨
sec_* 데이터 매칭	569 개 (34%)	나머지는 Evidence 로 LLM 폴백
name_formulation_code 추출	157 개 (9.4%)	Phase 1.5 이름 패턴 — LLM 힌트용
입력 파일	formulation_ingredients_master_audited.xlsx	원본이 별도 보유 필요

제형 계열별 분류

Formulation_ID 계열	수량	독성 연구 유형	Source_Files 특징
Cancer_PID_*	17 개	암 연구	cancer.xlsx
Eyelrritation6pack_PID_*	613 개	안독성 (토끼)	eye_irritation_rabbit_mixture...xlsx
MIX_PID_* 외	1,045 개+	피부독성/급성독성	skin_irritation, acute_dermal, acute_oral 혼재

3. 파이프라인 구조

```

[입력] formulation_ingredients_master_audited.xlsx (1,675 행)
|
▼ Phase 0.5 — pdf_section_extractor.py ✓ 완료
PDF 411 개 파싱 → section_extracts/ JSON (GHS·위험도·규제 정보)
|
▼ Phase 1 — enrich_with_sections.py ✓ 완료
1,675 행 + PDF 파싱값 합치기 → enriched_queue.csv
|
▼ Phase 1.5 — pre_fill_merge.py ✓ 완료 [NEW]
Formulation_Name 패턴 추출 → name_formulation_code 컬럼 추가
sec_formulation_code (PDF) + name_formulation_code (이름패턴) 분리 전달
불일치 6건 → A1이 sec1_text 원문으로 최종 판단
→ enriched_queue_prefilled.csv
|
▼ Phase 2 — extract_formulation_features.py ← API 비용 발생
|
| Cancer_PID 17 행 → 규칙 처리 (LLM 0 회) |
| 나머지 1,658 행 → 50 행 배치 × 34 회 |
| [A1] 제형타입 [A2] 위험도 [A3] 용도 |
| [A4] 규제 [A5] 성분프로파일 (동시 실행) |
| ※ A1은 sec_formulation_code + name_formulation_code 둘 다 수신 |
| 불일치 시 sec1_text 원문 기준으로 최종 결정 |
|
[출력] artifacts/formulation_characteristics_output.csv / .xlsx
(1,675 행 × 약 35 컬럼)

```

A1 에이전트 제형 코드 결정 로직 (Phase 1.5 추가)

상황	A1 판단 방법
sec_formulation_code 있음, name 없음	PDF 값 채택 (신뢰도 HIGH)
name_formulation_code 있음, sec 없음	이름 패턴 채택 (신뢰도 MEDIUM)
둘 다 일치 (동일 코드)	해당 코드 채택 (신뢰도 HIGH)
둘 다 불일치 (예: PDF=EC, Name=WP)	sec1_text 원문 기준으로 최종 판단
둘 다 없음	Formulation_Name + Audit_Evidence_Snippet 기반 추론

처리 시간 및 비용 예상

단계	소요 시간	AWS/API 비용	비고
Phase 0.5 (PDF 파싱)	~2 분	없음	이미 완료됨
Phase 1 (데이터 조인)	~10 초	없음	이미 완료됨
Phase 1.5 (이름 패턴 추출)	~5 초	없음	이미 완료됨 [NEW]
Phase 2 (LLM 추출)	15~20 분	Bedrock Sonnet 요금 발생	170 회 Claude API 호출
결과 저장	즉시	없음	CSV + XLSX 자동 생성

4. 배포 패키지 파일 구조

압축 파일(formulation_pipeline_20260713.zip)에 포함된 구성입니다.

```
formulation_pipeline_20260713.zip
├── agents/
│   ├── orchestrator.md ← 전체 파이프라인 실행 규범
│   ├── formulation_type_classifier.md ← A1 에이전트 스펙
│   │   (sec_formulation_code + name_formulation_code
│   │   두 힌트 수신 로직 포함)
│   ├── hazard_profile_extractor.md ← A2 에이전트 스펙
│   ├── use_application_extractor.md ← A3 에이전트 스펙
│   ├── regulatory_feature_extractor.md ← A4 에이전트 스펙
│   ├── active_ingredient_profiler.md ← A5 에이전트 스펙
│   └── pdf_section_extractor.md ← Phase 0.5 스펙
├── workflow/
│   ├── run_pipeline.py ← 마스터 실행 스크립트
│   ├── enrich_with_sections.py ← Phase 1
│   ├── pre_fill_merge.py ← Phase 1.5 (NEW)
│   ├── extract_formulation_features.py ← Phase 2 (LLM)
│   └── pdf_section_extractor.py ← Phase 0.5
├── requirements.txt ← Python 패키지 목록
├── artifacts/
│   ├── enriched_queue.csv ← Phase 1 결과 (1,675 행)
│   └── enriched_queue_prefilled.csv ← Phase 1.5 결과 (+name_formulation_code) (NEW)
├── ingredient_source_audit/
└── section_extracts/ ← PDF 파싱 결과 JSON 411 개 (Phase 0.5 재실행 불필요)
```

※ formulation_ingredients_master_audited.xlsx (마스터 워크북)은 별도 보유 필요합니다.

5. 실행 방법

사전 준비

- ① 압축 해제 후 `formulation_ingredients_master_audited.xlsx` 를 루트 폴더에 배치

- ② Python 패키지 설치

```
pip install -r requirements.txt
```

- ③ AWS Bedrock 환경변수 설정

```
export AWS_ACCESS_KEY_ID=<your_key>
export AWS_SECRET_ACCESS_KEY=<your_secret>
export AWS_DEFAULT_REGION=us-east-1
```

실행 명령

- Phase 0.5~1~1.5 완료, Phase 2 만 실행 (권장)

```
python workflow/run_pipeline.py --from-phase 2
```

- Phase 1.5부터 재실행 (name 패턴 재추출 후 Phase 2)

```
python workflow/run_pipeline.py --from-phase 1.5
```

- 처음부터 전체 실행

```
python workflow/run_pipeline.py
```

- 현재 상태 확인

```
python workflow/run_pipeline.py --status
```

- 중단 후 재시작 (캐시 활용)

```
python workflow/run_pipeline.py --from-phase 2 # 자동으로 중단점부터 재개
```

모델 변경 (선택)

AWS Bedrock 콘솔에서 활성화된 모델 ID 로 오버라이드 가능합니다.

```
export BEDROCK_MODEL_ID=us.anthropic.claude-3-5-sonnet-20241022-v2:0
```

6. 출력 결과

실행 완료 후 artifacts/ 폴더에 2 개 파일이 생성됩니다.

```
artifacts/formulation_characteristics_output.csv ← 분석용  
artifacts/formulation_characteristics_output.xlsx ← 엑셀 직접 열기
```

출력 컬럼 구조

그룹	컬럼명	예시 값	설명
식별자	Formulation_ID	Eyelrritation6pack_PID10	제형 고유 ID
식별자	Formulation_Name	Atlantis Herbicide	제품명
A1 제형타입	formulation_code	SC	Suspension Concentrate
A1 제형타입	physical_form	liquid	물리적 형태
A1 제형타입	type_confidence	HIGH	추출 신뢰도
A2 위험도	signal_word	WARNING	GHS 신호어
A2 위험도	h_codes	H302;H400;H410	위험 문구 코드
A2 위험도	hazard_level_score	3	위험도 점수 (0-5)
A3 사용목적	use_class	study/eye_irritation_rabbit	사용 목적 분류
A3 사용목적	target_pest_organism	weeds	대상 생물
A4 규제	epa_reg_number	432-1234	EPA 등록번호
A4 규제	registration_status	registered	등록 상태
A5 성분	active_pct_total	42.5	활성성분 총 %
A5 성분	formulation_complexity_score	3	성분 복잡도 (1-5)

실행 직후 터미널 품질 요약

```
=== 품질 검증 ===  
formulation_code UNKNOWN 비율: 28.3% (목표 < 40%)  
use_class 추출률: 91.4% (목표 >= 85%)  
epa_reg_number 발견률: 8.2% (목표 >= 10%)
```

```
저장 완료:  
CSV: artifacts/formulation_characteristics_output.csv  
XLSX: artifacts/formulation_characteristics_output.xlsx  
총 행: 1675, 총 컬럼: 35
```

7. 품질 게이트 (자동 검증 항목)

Phase 2 완료 직후 자동으로 검증합니다. 실패 항목이 있으면 에이전트 프롬프트 조정 후 재실행합니다.

#	검증 항목	통과 기준	실측 베이스라인
G1	전체 행 존재	1,675 행 모두 출력	—
G2	signal_word UNKNOWN 비율	< 30%	sec_signal_word 20.6% 확보
G3	use_class 추출률	≥ 85%	연구유형 규칙 추가로 목표 달성 가능
G4	Cancer_PID use_class	= research/cancer_study 100%	규칙으로 보장됨
G5	formulation_complexity_score	이상치(범위 밖) 없음 1-5 범위	—
G6	active_pct_total > 100% 행	0 또는 inconsistent 태깅	—
G7	formulation_code UNKNOWN 비율 < 40%		sec_formulation_code 7.8% + name_formulation_code 9.4% (Phase 1.5) → A1 힌트 풀 보강
G8	Pair integrity	formulation_code 비null & ≠UNKNOWN → physical_form + product_category + concentration_type 모두 비null	Phase 2 후 자동 검증 (위반 시 formulation_code → null 로 클리어)

8. 주의사항

- AWS 자격증명(AWS_ACCESS_KEY_ID, AWS_SECRET_ACCESS_KEY)은 환경변수로만 사용하고 코드에 직접 입력하지 마세요.
- Phase 2 실행 중 중단되면 extraction_cache/ 폴더에 완료된 배치가 저장됩니다. 재실행 시 자동으로 이어서 처리됩니다 (비용 중복 없음).
- formulation_ingredients_master_audited.xlsx 파일은 압축 파일에 포함되지 않았습니다. 별도로 준비해야 합니다.
- 성분 추출(ingredient-level) 작업은 이 파이프라인의 범위 밖입니다. 제형 특성(formulation-level) 5 차원만 추출합니다.
- Bedrock 에서 모델이 활성화되지 않은 경우 AWS 콘솔 → Bedrock → Model access 에서 활성화 후 재실행하세요.
- (Phase 1.5) extraction_cache/ 에 저장된 기존 배치는 name_formulation_code 힌트가 없는 상태로 캐시된 것입니다. 힌트 효과를 완전히 반영하려면 --force 옵션으로 Phase 2 를 재실행하세요.
- (Phase 1.5) enriched_queue_prefilled.csv 는 검수용 중간 파일입니다. Phase 2 는 이 파일을 직접 입력으로 사용하지 않으며, load_review_queue() 내부에서 인메모리로 name_formulation_code 컬럼을 추가합니다.