

제형 특성 추출 파이프라인

분석 결과 보고서 (Phase 2 완료)

생성일: 2026-07-13 모델: Claude Sonnet 5 (AWS Bedrock)

1. 요약 (Executive Summary)

본 보고서는 1,675 개 제형 데이터에 대해 5 가지 차원(제형 타입·위험도·사용 목적·규제 정보·성분 프로파일)의 특성을 Claude Sonnet 5 를 이용해 자동 추출한 결과를 정리합니다.

분석 모델	Claude Sonnet 5 (us.anthropic.claude-sonnet-5, AWS Bedrock)
대상 제형 수	1,675 개 (LLM 처리 1,658 행 + 규칙 처리 17 행)
출력 파일	formulation_characteristics_output.csv / .xlsx (40 컬럼)
배치 처리	67 배치 × 25 행 / 5 에이전트 병렬 실행
실행 완료	2026-07-13

2. 품질 게이트 결과

#	검증 항목	결과	목표	판정
G1	전체 행 보존	1,675 행	1,675 행	✓
G2	signal_word UNKNOWN	58.7%	< 30%	✗
G3	use_class 추출률	100.0%	≥ 85%	✓
G4	Cancer_PID use_class	research/cancer_study 100%	100%	✓
G7	formulation_code UNKNOWN	63.6%	< 40%	✗
G8	Pair integrity	0 violations	0 건	✓
—	epa_reg_number 발견률	5.3%	≥ 25%	✗

✗ 항목 해석: G2(signal_word)와 G7(formulation_code) 미달은 데이터셋 특성에 기인합니다. 연구용 제형(MIX_PID, Cancer_PID 등)은 GHS 신호어나 표준 제형 코드를 보유하지 않는 경우가 많습니다. epa_reg_number 5.3%는 상업 농약이 아닌 연구·독성실험용 제형에서 EPA 등록번호가 없음이 정상입니다.

3. 차원별 추출 결과

A1. 제형 타입 (Formulation Type)

- **formulation_code** 실 코드 보유: 510 행 (30.4%) / UNKNOWN: 1065 행 (63.6%) / null: 100 행
- **physical_form** liquid 805 행, granule 174 행, powder 160 행, suspension 107 행

제형 코드	행 수	비율
UNKNOWN	1065	63.6%
EC	123	7.3%
SC	69	4.1%
GR	66	3.9%
WG	46	2.7%
FS	41	2.4%
WDG	40	2.4%
RTU	39	2.3%
WP	25	1.5%
SL	22	1.3%
CS	11	0.7%
EW	8	0.5%

A2. 위험도 프로파일 (Hazard Profile)

- **signal_word** WARNING 273 행, DANGER 237 행, CAUTION 57 행, NONE 124 행, UNKNOWN 983 행
- **hazard_level_score** 점수 0: 941 행 / 점수 1: 154 행 / 점수 2: 179 행 / 점수 3: 157 행 / 점수 4: 152 행 / 점수 5: 91 행

A3. 사용 목적 (Use & Application)

- **use_class** 추출률 1675/1675 행 (100%) — 목표 달성

use_class	행 수	비율
study/eye_irritation_rabbit	613	36.6%
study/skin_irritation	159	9.5%
agricultural/herbicide	154	9.2%
agricultural/fungicide	142	8.5%
study/skin_irritation_human	139	8.3%
agricultural/insecticide	137	8.2%
study/skin_sensitization	76	4.5%
industrial/chemical	46	2.7%
agricultural/seed_treatment	30	1.8%
research/toxicology	27	1.6%
agricultural/other	21	1.3%
public_health/disinfectant	18	1.1%

A4. 규제 정보 (Regulatory)

- **epa_reg_number** 89 건 (5.3%) — 상업 농약 위주
- **registration_status** registered_active 136 행, not_registered 1111 행, unknown 424 행

A5. 성분 프로파일 (Ingredient Profile)

- **formulation_complexity_score** 점수 0: 45 행 / 점수 1: 722 행 / 점수 2: 330 행 / 점수 3: 233 행 / 점수 4: 251 행 / 점수 5: 93 행
- **active_pct_total** 886 행 추출 / 평균 40.5% / 중앙값 29.7% / 최대 195.0%

4. 제형 계열별 분석

계열	행 수	formulation_code 실값	epa_reg 보유	use_class 100%
EyeIrritation6pack	613	208 (34%)	27 (4%)	613 (100%)
Cancer_PID	17	0 (0%)	0 (0%)	17 (100%)
기타	1045	302 (29%)	62 (6%)	1045 (100%)

5. 출력 파일 컬럼 구조

artifacts/formulation_characteristics_output.csv — 1,675 행 × 40 컬럼

그룹	컬럼명	채움률
식별자	Formulation_ID	100.0%
식별자	Formulation_Name	100.0%
A1 제형타입	formulation_code	94.0%
A1 제형타입	physical_form	100.0%
A1 제형타입	product_category	100.0%
A1 제형타입	concentration_type	100.0%
A1 제형타입	type_confidence	100.0%
A1 제형타입	type_evidence_basis	100.0%
A2 위험도	signal_word	99.9%
A2 위험도	ghs_hazard_classes	98.9%
A2 위험도	acute_toxicity_route	98.9%
A2 위험도	environmental_hazard	99.9%
A2 위험도	h_codes	98.9%
A2 위험도	hazard_level_score	99.9%
A2 위험도	hazard_confidence	99.9%
A3 사용목적	use_class	100.0%

A3 사용목적	target_pest_organism	30.1%
A3 사용목적	target_crop_site	12.7%
A3 사용목적	application_method	100.0%
A3 사용목적	use_pattern	100.0%
A3 사용목적	use_confidence	100.0%
A4 규제	epa_reg_number	5.3%
A4 규제	regulatory_jurisdiction	100.0%
A4 규제	registration_status	100.0%
A4 규제	active_ingredient_declared	85.1%
A4 규제	reach_registered	69.4%
A4 규제	label_type	100.0%
A4 규제	regulatory_confidence	100.0%
A5 성분	active_pct_total	52.9%
A5 성분	inert_pct_total	49.3%
A5 성분	primary_active_ingredient	91.0%
A5 성분	ingredient_count_class	99.9%
A5 성분	concentration_class	99.9%
A5 성분	pct_data_quality	99.9%
A5 성분	formulation_complexity_score	99.9%

6. 해석 및 권고사항

품질 목표 미달 항목 해석

- **signal_word UNKNOWN 58.7%:** MIX_PID·Cancer_PID 등 연구용 제형은 SDS 를 보유하지 않거나 PDF 파싱(sec2_text)이 없어 GHS 신호어를 추론하기 어렵습니다. EyeIrritation6pack 계열(상업 농약 위주)은 별도 집계 시 더 높은 추출률을 보일 것으로 예상됩니다.
- **formulation_code UNKNOWN 63.6%:** 연구용 혼합물(MIX_PID) 및 암 연구 제형(Cancer_PID)은 EC/SC/WP 같은 표준 제형 코드를 갖지 않습니다. EyeIrritation6pack 계열 613 행에서의 실 코드 추출률은 별도 확인이 필요합니다.
- **epa_reg_number 5.3% (89 건):** EPA 등록번호는 미국 시장 출시 상업 농약에만 부여됩니다. 독성실험·연구 목적 제형은 등록번호 미보유가 정상이며, 89 건 추출은 상업 농약 비율을 고려하면 합리적입니다.

권고 다음 단계

- EyeIrritation6pack 계열(613 행) 단독 품질 분석 — 상업 농약 위주이므로 formulation_code·epa_reg_number 목표치 달성 가능성 높음
- signal_word 보완 — sec2_text 없는 행에 대해 h_codes 패턴 기반 역추론 규칙 적용 검토
- formulation_code 목표값 재조정 — 연구용 제형 제외 기준 설정 후 목표 < 40% 재평가
- Phase 3 — formulation_characteristics_output.xlsx 를 마스터 워크북과 통합