

Formulation Characteristics — Unknown Ratio 품질 리포트

파이프라인 출력 데이터의 필드별 미확인(unknown/null) 비율 분석 및 문제 진단

총 레코드 1,675건

분석 필드 40개

데이터 생성일 2026-07-13

최고 미확인율 필드

94.6%

epa_reg_number
(1,584 / 1,675)

위험·용도 동시 UNKNOWN

55.0%

signal_word & env_hazard 모두 unknown

조성 완전 미확인

48.6%

active% & inert% 둘 다 unknown

USE_CONFIDENCE HIGH

91.8%

use_class 분류는 안정적

전체 필드별 UNKNOWN 비율

필드별 미확인 비율 — 도메인 그룹별

빨간색 ≥ 70%, 주황 50-70%, 노랑 25-50%, 파랑 < 25%. 막대 클릭 시 상세 툴팁.

■ ≥ 70% 위기

■ 50-70% 심각

■ 25-50% 주의

■ < 25% 양호

ID / 물리적 특성

formulation_code		68.5%	1,148 / 1,675
physical_form		26.1%	437 / 1,675
concentration_type		22.9%	384 / 1,675
product_category		2.7%	46 / 1,675

위험·유해성


environmental_hazard		64.8%	1,086 / 1,675
signal_word		57.8%	968 / 1,675
ghs_hazard_classes		1.2%	20 / 1,675
acute_toxicity_route		1.2%	20 / 1,675
h_codes		1.2%	20 / 1,675

용도 / 적용


target_crop_site		88.6%	1,484 / 1,675
application_method		71.1%	1,191 / 1,675
target_pest_organism		70.7%	1,185 / 1,675



규제 / 등록



조성 / 성분



제품 카테고리 x 주요 필드 — UNKNOWN 비율 히트맵

카테고리별 핵심 6개 필드 unknown 비율 (%)

셀 색은 unknown 비율 크기. 짙을수록 데이터 공백 심각.


카테고리 (n)	target_pest	target_crop	app_method	epa_reg_no	env_hazard	signal_word
pesticide/insecticide (414)	65%	81%	62%	93%	70%	58%
pesticide/herbicide (316)	61%	84%	62%	94%	65%	61%
pesticide/fungicide (339)	51%	89%	56%	91%	69%	60%
pesticide/other (56)	77%	82%	68%	95%	77%	64%
pesticide/rodenticide (6)	67%	67%	67%	67%	67%	50%
consumer_product (192)	99%	99%	98%	100%	43%	39%
industrial_chemical (177)	92%	97%	95%	97%	55%	52%
cleaning_disinfectant (45)	69%	87%	69%	93%	69%	56%
pharmaceutical (12)	92%	100%	75%	100%	42%	42%
wood_preservative (20)	65%	90%	65%	95%	80%	75%
research_compound (35)	100%	100%	100%	100%	71%	69%
research/cancer_study (17)	100%	100%	100%	100%	100%	100%

카테고리 (n)	target_pest	target_crop	app_method	epa_reg_no	env_hazard	signal_word
unknown (45)	96%	98%	98%	100%	82%	82%

신뢰도(CONFIDENCE) 분포 — 도메인별

5개 도메인 신뢰도 누적 막대

HIGH(녹) / MEDIUM(주황) / LOW(적) 비율. 낮을수록 파이프라인 추론 불확실.



핵심 문제 진단

△ 문제 1 — 규제 추적 불가

epa_reg_number 94.6% unknown. 살충제·제초제·살균제 카테고리에서도 91-93%가 비어 있음. EPA 번호 없이는 농약 등록 여부 확인 자체가 불가능하며, 라벨 검색·성분 검증의 출발점이 사라짐.

△ 문제 2 — 사용 맥락 전면 공백

target_crop_site **88.6%**, application_method **71.1%**, target_pest_organism **70.7%**, use_pattern **70.6%** — 제품의 "어디에, 어떻게, 무엇을 위해" 정보가 거의 존재하지 않음. 노출 평가 및 위해성 모델링에 치명적.

△ 문제 3 — 안전 분류 신뢰 불가

signal_word **57.8%**, environmental_hazard **64.8%** unknown. 이 두 필드가 동시에 unknown인 레코드가 **921건 (55%)**. hazard_confidence도 57%가 LOW — GHS 위험성 분류 자체가 불완전.

△ 문제 4 — 조성 데이터 결손 연쇄

active_pct_total **49.3%**, inert_pct_total **52.2%**, 둘 다 unknown인 레코드 **814건(48.6%)**. concentration_class **46.4%**, ingredient_profile_confidence **47.3%**도 미확인 — 조성 정보 반이 없는 상태.

△ 문제 5 — research 카테고리 완전 공백

research/cancer_study(n=17), research_compound(n=35) 카테고리는 추적 필드 6개 모두 **100% unknown**. unknown 카테고리 자체(n=45)도 44/45가 공백. 총 97건이 데이터가 전무한 레코드.

△ 문제 6 — formulation_code 식별 불가

formulation_code **68.5% unknown**. 제형 코드가 없으면 동일 제품 중복 감지, 버전 추적, 외부 데이터베이스 조인이 모두 불가. 레코드 동일성 보장 수단이 Formulation_ID뿐인 상태.