

SMILES 기반 제형 GHS 분류 모델 (L3)

문서 정보 | 작성일 2026-09-15 | 작성 [이름 입력]

① 다중조각 SMILES 처리 현황 ② 모델 개발 현황 ③ 팀 공통 규약(EU_CLP) 적용 결과

1. 다중조각 SMILES 처리 현황

1-1. 문제 발견

성분 5,287행 중 SMILES 파싱 성공 3,580행(67.7%). 그중 **469행(13.1%)**이 ``으로 구분된 다중조각 SMILES.

두 가지 화학적으로 다른 경우가 혼재: - **염·수화물**: 활성물질 1개 + 나트륨 등 짝이온. 이온결합을 SMILES가 하나로 못 그려서 점으로 분리(예 [Na+].COC(=O)...). 실제로는 물질 1개. - **진짜 혼합물**: 서로 다른 물질 2개 이상이 성분 1행에 같이 기재(예 C1CO1.CC1CO1, 에틸렌옥사이드+프로필렌옥사이드). 실제로 물질 2개, 둘 다 자극성에 영향 가능.

원본 파이프라인은 이 둘을 구분하지 않고 전체를 하나의 분자로 계산 → 염은 짝이온 원자량이 활성물질 값에 더해지고, 혼합물은 서로 다른 두 분자 값이 단순 합산되는 왜곡 발생(파싱 에러 없이 조용히 발생).


1-2. 분류 기준 정립

1차 시도 — heavy atom 4개 이상을 "큰 조각"으로 정의:

큰 조각 개수	건수	해석
0개	61	순수무기물 등
1개	282	주성분 + 이온/물 (염·수화물)
2개	119	실제 혼합물
3개	7	동일 리간드 3개 + 금속 (착화합물)

→ 문제: 탄산·황산·질산·인산 이온, 이소프로필아민·에탄올아민 등 짝이온도 원자수가 많아 "큰 조각"으로 오분류됨(메실산염 원자 5개 등).

2차 — 데이터에 실제 등장하는 대이온을 근거로 **화이트리스트 62종** 구축(작은 조각 38종 자동 수집 + 애매한 크기 조각 화학적 판단으로 24종 추가) 후 재분류:



- 화이트리스트 기준 염·수화물 229건 중 **42건(18.3%)**은 최대조각의 InChIKey가 데이터셋 내 다른 곳에서 염 없이 단독 성분으로 실제 등장 → 최대조각 선택의 타당성 교차검증.

1-3. 검토한 처리방법 8가지

방법	내용
A. 최대조각 선택	heavy atom 최다 조각만 사용
B. Parent 구조 복원	최대조각 선택 후 이온 중성화
C. 조각별 평균	혼합물 각 조각 디스크립터 단순평균
D. 반복개수 가중평균	동일 조각 반복 시 개수로 가중
E. 지문 합집합	MACCS/Morgan 조각별 계산 후 OR
F. 원본 그대로	대조군
G. 대이온 화이트리스트	원자수 대신 데이터기반 62종 목록으로 판정
H. InChIKey 교차검증	최대조각 InChIKey의 단독성분 존재 여부 확인

전체 5,287건에 대해 8가지 결과를 엑셀로 전부 정리, 실제 재학습은 4가지로 축소: ① 원본(F, 대조군) ② 무조건 최대조각(A) ③ 염·수화물=최대조각/혼합물=평균, 원자수 기준 분기(AC_atomcount) ④ ③과 동일 + 화이트리스트 기준 분기(AC_whitelist).

우리가 완제품.. 혼합물을 평가하는 모델이니까 디스크립터가 염을 0으로 취급하는게 맞는지?

2. 모델 개발 현황

2-1. 현재

제형 눈·피부 2개 endpoint × 4가지 SMILES 처리방법 = 8개 모델 구동·성능 측정 완료.

- 구현 중 발견한 버그: `Chem.GetMolFragments(..., sanitizeFragments=False)`가 조각 재살균화를 생략시켜 TPSA·고리개수 등 디스크립터가 조용히 NaN 반환 → `sanitizeFragments=True`로 수정 후 전체 재계산. - 피처: RDKit 2D 디스크립터 19종 + MACCS 167비트 + Morgan 256비트, 독립 구현 (저장소 사전계산값 미사용).

2-2. 초기 비교 (K_REACH 관찰, 임계값 0.5 고정)

endpoint	F	A	AC_atomcount	AC_whitelist
눈 AUC	0.6577	0.6568	0.6625	0.6601
피부 AUC	0.7280	0.7250	0.7243	0.7233


→ 눈은 혼합물 구분 처리(AC_atomcount/AC_whitelist)가 원본보다 소폭 개선, 피부는 원본이 가장 높음. 방법 간 차이는 크지 않음.

2-3. 팀 공통 규약(EU_CLP) 적용 재평가

총책임자 배포 공통 규약(`공통규약.zip`, 2026-09-14) 적용. 검증 중 배포본이 macOS 압축(`\_MACOSX` 동반)이라 Windows에서 한글 파일명이 유니코드 정규화(NFD) 불일치로 깨지는 문제 발견·수정(NFC 재정규화) — `load\_common.py` 자체검사 정상 통과 확인.

항목	기존	공통 규약
대표 관찰	K_REACH	**EU_CLP**
눈 라벨	2B=양성, 양성 713	2B=음성, **양성 386**
피부 라벨	양성 371	**양성 356**
폴드	자체 생성	**공통폴드.npz 고정**
임계값	0.5 고정	**중점CV+Youden's J, 폴드별 선택**
AUC	pooled만	**pooled+누출보정 병기**, 게이트는 보정값
게이트	AUC≥0.686	**누출보정 AUC≥0.70**

팀 공통 규약(EU_CLP) 적용 후 4가지 방법 성능



endpoint	method	pooled AUC	누출보정 AUC	MCC	τ 평균(범위)	게이트
눈	F	0.6913	0.6575	0.3082	0.478(0.42-0.57)	미달
눈	A	0.6870	0.6517	0.3029	0.493(0.41-0.65)	미달
눈	AC_atomcount	0.6932	0.6588	0.2958	0.477(0.39-0.65)	미달
눈	AC_whitelist	0.6935	0.6599	0.3008	0.474(0.37-0.54)	미달
피부	F	0.7308	0.7095	0.3389	0.463(0.37-0.61)	달성
피부	A	0.7322	0.7084	0.3316	0.463(0.36-0.55)	달성
피부	AC_atomcount	0.7294	0.7055	0.3208	0.462(0.34-0.59)	달성
피부	AC_whitelist	0.7294	0.7063	0.3373	0.462(0.36-0.55)	달성

→ 피부는 4가지 방법 모두 게이트 통과, 눈은 4가지 방법 모두 미달. SMILES 처리방법 간 차이는 이 규약 하에서도 작음 — 눈 자극성은 SMILES 처리방식의 문제가 아니라 구조 정보만으로는 설명력이 부족한 endpoint로 판단됨.

2-4. 산출물

`C:\Users\WJSD\Desktop\연구 모델개발 최종본\` : 분류/비교 엑셀 6종(`SMILES\_다중조각\_분류\_전체.xlsx`, `방법1~3\_.xlsx`, `모델성능비교\_4개방법.xlsx`, `방법별\_최적모델\_탐색결과.xlsx`, `공통규약\_평가결과\_EU\_CLP.xlsx`)
 - 최종 모델 파일 14개(`joblib`, 방법×endpoint×규약별) + 설명표(`모델파일\_설명.xlsx`) -
 종합보고서(`SMILES\_다중조각\_처리\_보고서.pdf`)