

신작물보호제 제형 GHS 분류 모델

문서 정보 | 회의일 2026-09-15 | 작성 한서윤

① 데이터 현황 ② 모델 개발 현황

1. 데이터 현황

1-1. 현재

1. 노선 분리

피쳐는 어떻게 준비되어 있는지가 제일 중요
positive 얼마나 틀렸는 지 수치화하는게 필요.
정밀감도, 정확도 등

모델 1: 완제품 SDS / 모델 2: 성분별 MSDS 정보 * 성분 + 혼합물 조성 / 모델 : 성분
SMILES 구조 성분 정보와 GHS 혼합물 분류 규칙만으로 완제품 GHS 분류 성능을
측정하는 것이 목표.

2. 산출물

제형 단위 눈(eye)·피부(skin) 2 개 모델.

3. 관할

데이터 중 규제를 가르는 관할 (눈 구분 2B 분류 / 피부 구분 3 을 분류)

EU CLP 는 둘다 유해 분류로 안보므로, 우선 규제는 EU CLP 기준으로 적용함.

1-2. 규모

1. 전체

제형 1,675 개 · 성분행 5,287 개 · 제형당 성분 평균 3.16 개.

[그림 1] 원본 1,675개 제형 → 학습 1,044 / 1,059행 → 규칙이 말을 하는 행 1,044 / 1,059




그림 1. 원본 1,675 개 제형에서 가산 규칙이 판정을 내는 행

2. 학습에 들어가는 범위

- EU CLP 라벨 보유행만 남길시: 눈 1,044 행 / 피부 1,059 행. (양성 비율 눈 0.370 / 피부 0.336.)
 - GHS 가산식(UN GHS 3.3 혼합물 가산성)이 실제로 판정을 내는 행: 눈 607 / 피부 552.
- cf. 성분 정보(구분+농도)가 최소 1 개라도 갖춰진 제형만 GHS 가산식에 이용 가능

3. 평가 방식

5 개 시드 × 5 폴드 교차검증. 제형 그룹을 폴드에 걸치지 않게 묶음.

→ 1675 개 제형을 5 묶음으로 나누어 검증. (같은 제형에서 나온 성분행(예: 한 제형에 성분 3 개 = 행 3 개)이 학습 폴드와 검증 폴드에 쪼개져 들어가면 안 되므로)

1-3. 병목은 GHS 구분이 X, 농도

1. 성분 GHS 구분 결측이 문제 확인 후 CLP Annex VI · ECHA C&L 에서 455 중 조사·반영

성분행 5,287 개 중 "농도는 있는데 GHS 구분(눈·피부 몇 등급인지)만 없는"

성분이 2,240 개 존재. 채우기 위해 PubChem 을 통해 CLP Annex VI(EU 법적 조화분류표)와 ECHA C&L(유럽화학물질청 신고 집계) 두 외부 규제 DB 를 조회 및 검증 후 출처 표시를 인용하여 채움.

→ 눈 구분 보유 성분행 2,578 → 3,043 로 늘어남.

2. 위 성분 추가해도 성능 변화 X

이유는 농도. 가산식은 구분과 농도를 둘 다 받아야 계산 가능하므로.

농도 보유 성분행은 5,287 행 중 3,166 행(59.9%)뿐. 구분을 아무리 채워도 가산식에 들어가는 행은 이 3,166 행 안쪽이고, 구분+농도가 함께 있는 행은 조사 후에도 2,558 행(48.4%).




그림 2. 구분을 465 행 채워도 농도 보유 행수(주황 파선)가 최대

cf. 가산식

UN GHS 부속서 I / EU CLP 부속서 I 공식 국제표준 가산식 사용

완제품 전체를 직접 독성시험한 데이터가 없을 때, "성분들을 어떤 등급으로, 몇 %씩 섞었는지"만으로 완제품 등급을 추정하는 수식. GHS 가 정한 표준 대체 방법.

2. 모델 개발 현황

2-1. 현재

제형 눈·피부 2 개 모델 구동·성능 측정 완료. 성분 GHS 조사·검수 완료.

- **규약 1.** 임계값 τ 는 폴드마다 따로 구해 그 폴드 검증행에만 적용. τ 를 평균해 쓰면 라벨이 새어 들어오므로 금지.
- **규약 2.** AUC 는 pooled(전체 검증행을 다 섞어 한번에 계산한 일반적인 AUC) 와 누출보정(라벨 출처 층 안에서만 따로 계산하여 가중합한 AUC) 둘을 항상 병기.
pooled 단독 인용할 시 성능 과대 추정 위험

2-2. 실험 설계

알고리즘: RandomForestClassifier($n_estimators=300$, $class_weight=balanced$,
 $min_samples_leaf=2$) — 눈·피부 독립 학습, 시드별 재적합

지표: pooled ROC-AUC + 누출보정 ROC-AUC(라벨출처층 내부, 게이트 판정 기준) ·
MCC · BA

train / val / test: 고정 test set 없음. StratifiedGroupKFold 5-fold(그룹=활성성분 공유
587 그룹, 라벨로 층화)를 시드 5 개로 회전 — 매번 다른 1/5 이 test 가 되어 전체 행이
정확히 한 번씩 test 로 채점됨. τ (분류 임계값)는 바깥 train 안에서 다시 내부 3-fold 로
val 을 만들어 Youden's J 로 정하고, 그 폴드 test 에만 적용(폴드 간 평균 사용 금지 —
라벨 누출).

[그림 3] 교차검증 구조 — StratifiedGroupKFold 5-fold(활성성분 587그룹) × 5시드, 내부 3-fold 로 임계값만 별도 결정




그림 3. 바깥 5-fold(시드 5 회 반복)로 test 를 회전시키고, 내부 3-fold 로만 임계값 τ 를 정함

2-3. 모델 성능 종합

	눈	피부
pooled AUC	0.7265	0.7015
누출보정 AUC	0.6580	0.6470
pooled → 보정 차이	-0.0685	-0.0545
MCC	0.342	0.280
BA	0.674	0.647

표 1. L2 단독 대표 셀 성능

→ pooled 와 보정의 차이: 초과분의 27~30%로 해석할 수 있는 문제점.

(모델이 성분 조성을 보고 맞힌 게 X, 라벨과 특성이 문서를 공유하는 행을 알아봤다는 의미.)

학습 방법: 랜덤 포레스트 (1. 표본이 적고, 특성이 많으므로. 2. 양성 비율 33%로 불균형... 등)

2-4. 성분 커버리지 MCC 성능

cf. 성분 커버리지: 그 제형에 들어간 성분들 중 GHS 구분을 아는 성분의 비율.

(예: 성분 4 개짜리 제형인데 2 개만 구분을 알면 커버리지 0.50.)

성분 커버리지	구성	눈 MCC	피부 MCC
0.00-0.25	MSDS 원문	0.174	-0.025
0.00-0.25	+ 조사반영	0.222	0.135
0.25-0.50	MSDS 원문	0.260	0.306
0.25-0.50	+ 조사반영	0.122	0.198
0.50-0.75	MSDS 원문	0.432	0.092
0.50-0.75	+ 조사반영	0.490	0.318
0.75-1.00	MSDS 원문	0.516	0.379
0.75-1.00	+ 조사반영	0.422	0.461

표 2. 성분 커버리지 구간별 규칙 단독 MCC — MSDS 원문(arm0) vs 조사반영 후(arm2). 굵게 = 그 구간의 더 높은 값

cf. 위 수치로 알아본 성분표 자체 결함

- **성분이 아닌 행이 523/5,287 행(9.9%) 섞여 있음** — 문장형 추출 이상치 294 행, 이름 결측 227 행, 주석·구조식·정정메모 24 행. (예: MIX268 성분명이 "cheese accounted for of the overall market of P-R cheese in 2017" 문장으로 들어가 있는 현상)
- MIX408 은 Nicosulfuron 이 두 행(25% + "98%→25%로 정정" 25%)으로 중복 입력돼 **농도가 두 번 더해짐**

- 농도 90% 이상인 성분행 307 개 — [technical 원제 규격\(Nicosulfuron 98%, Sulfur 99% 등\)](#)이 완제품 행에 그대로 섞여 있음. 원료이므로 완제품 X
- 유허계가 Sulfur / Sulphur / Elemental Sulfur / Sulfur, precipitated 4 개 표기로 흩어져 있어 성분 단위 집계가 갈림.
- 제형 15 개는 성분 농도합이 105%를 넘음.

2-5. 성분 GHS 값 추가 반영 실험 후 성능

1. 대조 방법

성분 GHS 조사값을 채운 뒤, 처리방식 5 개(arm)를 놓고 "성능이 실제로 달라졌나"를 봄. 시드 5 개로 돌려서 arm 마다 값이 5 개씩 나왔고, 이 값들의 차이를 대조.

2. 결과

좋아진 쪽으로 범위를 벗어난 경우는 X

눈 보정 AUC: 0.6580 → 0.6532 / 피부 L 0.6470 → 0.6497 로 둘 다 소폭 하락했지만 잡음 범위 안. 벗어난 것은 눈 조사후_NC 유지 손실 2 건뿐(MCC -0.0200 ± 0.0151 , BA -0.0084 ± 0.0069).

cf. 조사값의 70%은 NC(무해), 기존 파이프라인에서는 무해값을 가산식에 넣지 않고 유해정보만 넣었음. 이번 실험에서는 NC 넣었으나 이 값이 상당수 없어서 무해라고 판단한 데이터.

NC 까지 넣으면 손실(눈 보정 AUC -0.0080 , 피부 MCC -0.0161)

3. A0(MSDS 칸) 채움 — 채택 X

조사값 중 유해로 판정된 것만 A0(arm1, 원 MSDS 선언값만 사용 경로) 칸에 옮겨봤더니 계산 결과가 성능이 바뀌지 않음. 이미 A2(arm2, MSDS 가 없을 경우 조사값으로 보충 경로)가 그 값을 알아서 끌어다 쓰고 있어서 A0 로 옮기는 것은 무의미. 따라서 A0 채움 채택 X.