


최소빈 _ 완제품 자극성 예측 모델

산출물

- 데이터 - 완제품 SDS의 물성·제형 코드를 학습 가능한 표(1,675행 × 52열)로 정리
- 모델 - 공유 받은 파이프라인과 규제 기준 기반.

작업 간단히 설명

- 공유 받은 표(input_dataset_v6.xlsx)에서 완제품 SDS가 출처인 52열을 뽑아 데이터로 사용했다.
- 완제품 문서만 보았기 때문에 성분 조성을 알 수 없는 281행을 버리지 않았다.



1. 성능 - 같은 문서에서 온 정답의 이득을 걸어내면 얼마인가

- 1,675행 전부를 '정답(y)이 어디서 왔는지'로 분류했을 때
 - 정답이 feature와 같은 SDS 문서에서 나오면, 문서를 알아보고 맞히는 이득이 섞인다.
- 성능은 전체 vs 동물시험(NTP)의 가운데 값을 읽는다. 같은 문서에서 나왔다고 해서 문제가 아님. 라벨은 라벨대로, 피쳐는 피쳐대로 개발하면 되지 않는가..
 - 눈 0.664 · 피부 0.660 로, 1차 목표선 0.70 에는 미달했다.
- 정답이 동물시험인 행만 보면 눈 0.672 · 피부 0.646 다. - 순환 의심이 없는 값도 확보

1. 데이터 현황

1-1. 정리 결과

항목	내용
전체 크기	1,675행. (1행 = 완제품 1건)
독립 표본	587묶음. 주성분이 같은 제형은 사실상 같은 표본이라 묶어서 샘플
정답 (y)	Section 11 또는 NTP에 적힌 GHS 분류 (눈·피부 각각)
정답이 있는 행	눈 1,044행 · 피부 1,059행. 나머지는 '음성'이 아니라 '모른다'라서 제외
내가 쓰는 정보 (X)	52열 = 완제품 SDS 9절 물성 + 제형 코드 (성분 조성표·화학구조는 X)

- 내가 쓰는 정보 (X)

실수값 15열 (pH·밀도·융점 등 측정 물성)	0/1 표시 14열 (외관·용해도 표현)	0/1 표시 23열 (제형 코드·유형)
-------------------------------	---------------------------	--------------------------

공유 받은 표(input_dataset_v6.xlsx)에서 'SDS 문장 → 숫자' 변환이 잘 됐는지 검증 후 확정

Section 9에 정보가 아예 없으면 '없음' 칸에 1을 넣음 (값이 0 vs 정보 없음 구분)

1-2. 성분 조성을 모르는 281행


조성표가 없어 성분 비율을 알 수 없는 행이 존재한다. 다만, Section 9은 완성된 혼합물 자체를 측정한 값이고 제형 코드는 제품 라벨에 붙는 정보라서, 조성을 몰라도 데이터로 사용했다.

→ 학습 행 기준 눈 169행 · 피부 165행이 해당됨

단, 이 281행은 52열 빈칸 비율이 조금 높고 + 정답 확보율도 조금 낮음 (→ 문서 자체가 부실한 경향도)

1-3. 데이터 결측률

- 0/1 표시 (37열) – 0%
- 실수값 (15열) – 74.7%




3. 실수값의 결측률 - 한 행에 물성이 평균 4개만 채워져 있다

비어 있는 칸은 추정해 넣지 않고 '없음' 상태로 학습시킨다.

실수값 15열이 전부 비어 있는 행(200건)의 경우, 제형 코드와 물리적 상태 표시만으로 학습된다.

★ 52열이 전부 비어 있는 행은 0행이다 - '없음' 칸이 항상 값을 갖기 때문



4. 실질 표본 크기 — 1,675행이지만 독립 표본은 587개다


+) 주성분이 같은 제형을 묶음 단위로 잘랐을 때

→ 52열 대비 눈 442묶음 · 피부 477묶음은 뽀뽀한 비율 / 성능이 0.66 에서 머무는 이유 중 하나로 보인다.

1-4. 정답(y)의 출처


feature와 SDS를 공유하는 경우를 경계

→ 1,675행 전부를 정답 출처별로 분류해 두고, 그 분류를 모델이 읽어 쓰도록 만들었다.



5. 정답의 출처 구성 (완제품 1,675건 기준)

→ 눈 1,044행(608+436) / 피부 1,059행 (544+387+128)



6. 출처별 양성 비율 - 3~4배 차이가 남

+) 보정 근거 (문서를 알아보고 맞히는 이득)


2. 모델 현황

2-1. 성능 (기준 국가 EU · 빈칸 채우지 않음 · 완제품 52열)

	n	양성비율	ROC-AUC (전체)	ROC-AUC (보정)	MCC	재현율	특이도	PR-AUC
눈	1,044	0.370	0.7222	0.6642	0.3212	0.616	0.712	0.612
피부	1,059	0.336	0.7174	0.6605	0.3084	0.594	0.722	0.601

→ 굵게 표시한 **ROC-AUC (보정)** 열이 판정 기준이다.

(모든 값은 5회 반복 평균이고, 표준편차는 첨부 CSV 의 각 지표 _sd 열에 있다.)



7.. 정답 출처별로 나눠 본 성능

왼쪽(동물시험) – 데이터와 문서가 겹치지 않아 순환 의심 없이 '물성으로 맞혔다'고 말할 수 있는 값

→ 눈 0.672 · 피부 0.646

오른쪽 피부 0.900 는 성과로 인용하지 않는다 - 94행에 양성 14건이라 값이 흔들림

2-2. 실무 언어 표

지표	뜻
ROC-AUC (0.664 / 0.660)	무작위로 뽑은 분류 대상 1건과 비대상 1건 중 분류 대상에 더 높은 점수를 줄 확률.
재현율 (0.62 / 0.59)	실제로 분류해야 하는 제품 중 모델이 잡아내는 비율. 놓치면 미표시 위험이 남는다.
특이도 (0.71 / 0.72)	분류 대상이 아닌 제품을 제대로 통과시키는 비율. 낮으면 불필요한 시험 비용이 든다.
MCC	두 오류를 함께 보는 균형 지표. (0이 찍기, 1 이 완벽) →현재 0.32 수준이다.