

# 신작물보호제 L2 노선 피처 설계 및 실험 4 건

문서 정보 | 회의일 2026-09-22 | 작성 한서윤

① 요약 ② 피처 구성 ③ 실험 조건 ④~⑦ 실험 4 건 ⑧ 확인된 결함 ⑨ 다음 순서

## 1. 요약

L2 노선의 피처 설계를 확정하기 위해, 조건을 한 번에 한 가지만 바꾸는 실험을 4 건 돌렸습니다.

- 대표 구성은 L2 단독 42 열, 결측 규약은 native\_복원 으로 확정했습니다.
- 성능이 더 나은 구성이 2 개 있었지만 다른 노선의 정보를 더한 것이라 채택하지 않았습니다.
- 판정을 낼 때 가산식 원값 8 열이 가장 많이 쓰이고, 최종 판정(원-핫 11 열)이 가장 적게 쓰입니다.
- 42 열을 전수로 훑어 설계 결함 4 건을 확인했습니다.

## 2. 피처 구성

### 노선

성분별 MSDS 위험정보(눈·피부 몇 등급)와 농도만 피처로 사용합니다. 완제품 SDS 선언값과 성분 SMILES 구조는 각각 다른 노선 소유입니다.

- 라벨: 제형 단위. '이 제품이 눈에 위험한지 아닌지' 분류
- 피처(입력 재료): 성분 단위 정보. 그 제품에 들어간 성분들 각각의 MSDS 위험정보와 농도

### 열 수

L2 노선 단독 42 열입니다. 성분 정보와 농도만으로 구성했습니다.

### 넣은 것 (6 묶음, 42 열)

- ① 규칙이 내린 최종 판정 (11 열; f\_ct\_{eye,skin,sens}\_cat\_\*).

눈/피부/감작 각각 몇 등급인지를 원-핫으로 넣습니다.

- ② 같은 판정을 순서값으로 (6 열;  $ct_{\{ep\}}_{ord} \cdot f_{ct_{\{ep\}}_{ord}}$ ).

심각도 순서( $NC < 2 < 1$ ). 원-핫과 중복이지만 트리 분기 깊이가 다릅니다

- ③ 판정 직전의 가산식 원값 (8 열;  $f_{ct_{\{ep\}}_{s1} \cdot s2 \cdot add}$ ).

판정 직전의 가중합. 임계값( $3 \cdot 10 \cdot 20$ )에 걸리기 전의 연속량입니다.

- ④ 역할별 농도 (13 열;  $f_{pct} \cdot 12 \text{ 열} + f_{max\_pct}$ ).

활성성분·계면활성제·용매 등이 각각 몇 % 들었는지입니다. 성분명으로 역할을 추정해 역할별 농도를 합산합니다.

- ⑤ 조성이 얼마나 복잡한지 (2 열;  $f_{shannon} \cdot f_{simpson}$ ).

농도 분포 엔트로피. 단일물질 제형과 복합 제형을 가릅니다.

- ⑥ 규칙 적용 여부 표시 (2 열;  $ct_{not\_applicable} \cdot f_{has\_synergist}$ ).

규칙 자체가 적용 안되는 경우의 플래그와 협력제 유무입니다.

*cf. (트리모델이므로 스케일링 없음)*

## 제외한 것과 이유

- 완제품 물성 14 열 (pH·점도 등). 완제품 SDS 에 적힌 값이라 L1 노선 것입니다.

- 농도×구조 디스크립터 19 열. 농도(L2)와 성분 구조(L3)를 둘 다 알아야 계산됩니다.

- 계면활성제 전하별 농도 9 열. 전하 종류를 알려면 성분 구조(L3)가 필요합니다.

- pH 최종값 1 열. 아직 어느 노선 것인지 정해지지 않았습니다.

## 묶음마다 적용되는 계산식

### ①②③ — UN GHS 3.3 가산식

성분마다 등급(구분 1 / 구분 2 / 구분없음)과 농도를 곱해서 다 더하는 공식입니다.

- 구분 1 성분 농도합 =  $s_1$ , 구분 2 성분 농도합 =  $s_2$ , 최종 가중값  $add = 10 \times s_1 + s_2$

- 이  $add$  를 임계값  $3 \cdot 10 \cdot 20$ (가산식 공식 컷오프 농도)에 대입해서 등급을 정합니다.

③은 이 계산의 중간 숫자( $s_1 \cdot s_2 \cdot add$ ) 그대로, ②는 그 등급을 순서값으로, ①은 그 등급을 원-핫으로 표현한 것입니다. 하나의 수식 결과를 세 가지 형태로 반복해서 준 것입니다.

#### ④ 역할별 농도 — 농도 단순 합산

'활성성분으로 추정된 성분들의 농도를 다 더한다' 정도입니다. 등급 계산 없이 그냥 % 합입니다.

#### ⑤ 조성 다양성 — 엔트로피 공식

Shannon  $-\sum p \cdot \ln(p)$ , Simpson  $1/\sum p^2$  ( $p$  = 각 성분 농도 비율). 성분이 골고루 섞였는지 계산하는 정보이론 공식입니다.

#### ⑥ 이진 플래그 — 분류 값

조건을 만족하면 1, 아니면 0 입니다.

### 3. 실험 조건

실험 4 건에서 공통으로 고정한 조건입니다.

- **모델**: RandomForestClassifier( $n\_estimators=300$ ,  $class\_weight=balanced$ ,  $min\_samples\_leaf=2$ ). 눈·피부를 독립으로 학습합니다.
- **검증**: StratifiedGroupKFold 5-fold(그룹 = 활성성분 587 그룹) × 시드 5 개. 같은 제형에서 나온 성분행이 학습·검증에 쪼개져 들어가지 않게 묶습니다.
- **지표**: pooled AUC 와 누출보정 AUC 를 항상 병기하고, 게이트 판정은 누출보정  $AUC \geq 0.70$  으로만 합니다.
- **임계값  $\tau$** : 폴드마다 따로 구해 그 폴드 검증행에만 적용합니다. 폴드 간 평균은 라벨이 새어 들어오므로 쓰지 않습니다.

| 실험              | 바꾼 것                                    | 채점                   | 결과                  |
|-----------------|-----------------------------------------|----------------------|---------------------|
| 1. 결측 처리        | nan0 ↔ native_복원                        | 보정 AUC ·<br>MCC · BA | native_복원 채택        |
| 2. 피쳐셋 범위       | L2 단독 42 열 ↔ 노선혼합 arm<br>4 개 (최대 220 열) | 보정 AUC ·<br>MCC      | 혼합이 더 높지만<br>미채택    |
| 3. 규칙 출력<br>인코딩 | 원-핫 · 서수 · 원값 3 형태를<br>동시 투입            | 묶음별 중요도              | 원값이 1 위, 3 형태<br>유지 |
| 4. 농도 피쳐<br>기여  | 규칙 묶음 ↔ 농도 묶음                           | 묶음별 중요도              | 농도가 규칙과 대등          |

표 2. 실험 3·4 는 교차검증 점수가 아니라 설계 검토용으로만 실험했습니다.

## 4. 실험 1 — 결측 처리

**문제:** 수치 0 과 결함 0 이 한 열에 섞임

입력 생성 쪽에서 None 을 0.0 으로 바꾸는 관용구(or 0.0)가 계면활성제 농도 4 열을 합산할 때 걸려 있었습니다. 그래서 구성 4 열은 결측인데 합계 2 열만 0 이 되고, 결측 플래그열(\*\_isna)조차 생성되지 않아 나중에 되짚을 단서도 없었습니다. 조성을 아예 모르는 281 행이 '계면활성제가 0% 들어있다' 는 실측값과 구별되지 않게 된 것이고, 열 2 개 × 281 행 = 562 셀입니다.

( cf. 전수 확인 결과 만들어 넣은 0 은 이 2 열뿐이었습니다 — f\_pct\_surf\_total · f\_surf\_anionic\_nonionic. 나머지 0 은 전부 구조적 0 으로 확인했습니다. )

### 결과

| endpoint     | 결측 처리          | pooled AUC | 누출보정 AUC | MCC    | BA     |
|--------------|----------------|------------|----------|--------|--------|
| 눈 (n=1,044)  | nan0 (0 으로 채움) | 0.7028     | 0.6364   | 0.3087 | 0.6535 |
| 눈 (n=1,044)  | native_복원 (채택) | 0.7265     | 0.6580   | 0.3422 | 0.6738 |
| 피부 (n=1,059) | nan0 (0 으로 채움) | 0.6874     | 0.6326   | 0.2903 | 0.6495 |
| 피부 (n=1,059) | native_복원 (채택) | 0.7015     | 0.6470   | 0.2797 | 0.6465 |

표 3. 같은 42 열 · 같은 폴드에서 결측 규약만 바꾼 성능

### 결론

게이트 판정값이 눈·피부 둘 다 복원 쪽이 높아서 원칙과 성능이 같은 방향이었습니다. 피부 MCC 가 0.0106 낮은 것은 남기고 대표값은 native\_복원 으로 확정했습니다. nan0 은 v6 재현 대조용으로만 보존합니다.

### 해야 할 것

결측으로 되돌린 것은 값을 바로잡은 게 아니라 결측치로 정확히 표시한 것입니다. 진짜 해결은 원본 문서에서 실제 농도를 찾아오는 것인데 아직 데이터가 없어서 미뤄 둔 상태입니다.

- 1. 조성미상 281 행 채우기. 원본 MSDS·제품 조성표에서 계면활성제 조성을 다시

찾습니다. 채워지면 합계 2 열의 결측 562 셀도 같이 사라집니다.

- **2. 농도 결측 2,121 행 채우기.** 성분행 5,287 개 중 농도 보유는 3,166 개(59.9%)뿐입니다. 가산식은 구분과 농도를 둘 다 받아야 계산되므로 농도가 없는 행은 규칙에 못 들어갑니다.

→ 확인 방법. 구분과 농도를 함께 가진 행이 2,558 개(48.4%)에서 얼마나 늘었는지 확인하고, 누출보정 AUC 가 올라가는지 재측정합니다.

주의: 구분만 채우는 것으로는 안 된다는 것을 이미 확인했습니다. 외부 규제 DB 조사로 구분 보유 성분행을 2,578 → 3,043 으로 늘렸는데 성능이 거의 변화하지 않았습니다. 병목은 구분이 아니라 농도입니다(9 장). (누출보정 AUC — 눈 0.6580 → 0.6532 (-0.0048), 피부 0.6470 → 0.6497 (+0.0027))

( cf. 임퓨트(결측값을 0 으로 채우는 방식)를 안 해도 되는 이유는, 신버전 트리 모델인 sklearn ≥ 1.4 가 결측값을 그대로 분기 방향으로 학습하기 때문입니다. )

## 5. 실험 2 — 피쳐셋 범위

### 대조 방법

L1, L2, L3, L2+L3 arm 4 개를 L2 단독과 같은 폴드로 함께 실험했습니다.


- **L1 = 완제품 SDS 선언값 (52 열).** 완제품을 직접 측정해 SDS 에 적어 놓은 값입니다. pH·끓는점·인화점·밀도·점도·용해도 같은 물성 수치와, 제형 유형·물리적 상태·용해성 표기의 원-핫입니다.

- **L3 = 성분 SMILES 구조 (98 열).** 성분의 화학 구조에서 RDKit 으로 뽑은 값입니다. 분자량·logP·고리 수·수소결합 자리 같은 디스크립터 19 종을 제형 안 성분들에 대해 최대·평균·최소·범위·표준편차로 요약한 95 열과, 성분끼리 구조가 얼마나 닮았는지 3 열입니다.

- **L2·L3 결합 (28 열).** 두 노선 정보가 다 있어야 계산되는 열입니다. 구조값을 농도로 가중평균한 19 열, 계면활성제 전하별 농도 6 열(전하 종류를 구조에서 판별), 농도×구조 상호작용 3 열입니다.

| 피쳐셋         | 열 수 | 눈 보정<br>AUC | 눈 MCC  | 피부 보정<br>AUC | 피부<br>MCC | 게이트 0.70 |
|-------------|-----|-------------|--------|--------------|-----------|----------|
| L2 단독       | 42  | 0.6580      | 0.3422 | 0.6470       | 0.2797    | 미달       |
| L2+결합       | 70  | 0.6776      | 0.3742 | 0.6604       | 0.3193    | 미달       |
| L2+L1       | 94  | 0.6814      | 0.3728 | 0.7000       | 0.3587    | 피부 통과    |
| L2+L3       | 140 | 0.6911      | 0.4072 | 0.6840       | 0.3415    | 미달       |
| 전체_노선혼<br>합 | 220 | 0.6962      | 0.4158 | 0.7130       | 0.3684    | 피부 통과    |

표 4. arm 5 개 (EU CLP · 공통폴드 · native\_복원)



## 성능을 올려도 제외한 열

L2 노선이 '성분 정보와 GHS 혼합물 가산 규칙만으로 완제품 제형을 어디까지 분류할 수 있는가' 이므로, 다른 노선의 정보원이 있어야 계산되는 열은 성능을 올려도 일단 제외했습니다.

- **완제품 물성 14 열.** pc2\_ph·pc2\_logkow·pc2\_vp·pc2\_bp 등. 완제품 SDS 선언값이라 L1 노선 소유입니다.
- **농도가중 디스크립터 19 열.** f\_MolLogP\_wmean 등. 농도(L2)와 구조(L3)가 둘 다 있어야 계산됩니다.
- **전하별 농도·상호작용 9 열.** f\_pct\_surf\_anionic 등 6 열과 f\_solvent\_x\_logp 등 3 열. 전하 클래스가 RDKit SMARTS 유래입니다.
- **노선 귀속 미결 1 열.** ph\_best. 강산·강염기 비가산 예외 게이트가 아직 구현되지 않았습니다.
- **최소빈 담당 S11 판독.** 라벨을 읽은 문서 절에서 나온 값이라 피쳐로 쓰면 정답이

샘니다.

- 상수열 1 열. f\_pct\_thickener. 정상 탈락입니다 — 증점제로 찍힌 성분행이 2 개뿐이고 둘 다 농도 미상이라 전 제형에서 값이 0 입니다.

## 결론

피부 전체\_노선혼합 0.7130 이 게이트를 넘은 유일한 구성입니다.

## 6. 실험 3 — 규칙 출력 인코딩

**대조 방법:** 압축 단계가 다른 세 형태를 동시에 넣음

가산식의 출력을 어떤 형태로 모델에 줄지가 이 노선 설계의 핵심 결정이었습니다. 하나만 고르지 않고 원-핫(①)·서수(②)·원값(③) 세 형태를 같이 넣고 중요도로 되짚기로 했습니다.

( cf. 중요도는 랜덤포레스트 feature\_importances\_ 의 시드 5 개 평균입니다. 상관된 열끼리 중요도를 나눠 갖는 성질이 있어서 개별 절대값을 인용하지 않고 묶음 합만 읽습니다. )

| 묶음            | 열 수 | 눈 합   | 피부 합  | 눈 열당  | 피부 열당 |
|---------------|-----|-------|-------|-------|-------|
| ③ 가산식 원값      | 8   | 36.8% | 36.0% | 4.61% | 4.50% |
| ④ 역할별 농도      | 13  | 33.9% | 34.4% | 2.61% | 2.64% |
| ② 규칙 판정 (서수)  | 6   | 11.5% | 11.8% | 1.92% | 1.97% |
| ⑤ 조성 다양성      | 2   | 10.1% | 10.3% | 5.05% | 5.14% |
| ① 규칙 판정 (원-핫) | 11  | 7.4%  | 7.3%  | 0.67% | 0.67% |
| ⑥ 이진 플래그      | 2   | 0.2%  | 0.2%  | 0.08% | 0.11% |

표 5. 묶음별 중요도. 합으로는 가산식 원값이 1 위, 열당으로는 조성 다양성 2 열이 1 위(5.05%)이고 가산식 원값이 2 위(4.61%)입니다




그림 2. 상위 12 개. 가산식 원값(\_add\_s1)·최대농도·유효성분 농도·다양성 지수가  
상위권

## 읽는 법

규칙의 최종 판정을 피쳐로 주는 것은 거의 효과가 없었습니다. 원-핫 11 열 + 서수 6 열 = 17 열이 합쳐서 18.9%(눈)인데, 그 판정을 만들어 낸 원값 8 열이 36.8%입니다. 개별로도 f\_ct\_eye\_add 9.3% 가 단일 최고이고 f\_ct\_eye\_cat\_2A 는 0.4%입니다.

## 결론

가산식은 임계값(3, 7, 10)에서 정보를 버립니다. add=9.8 과 10.2 가 같은 구분으로 압축되는데, 원값을 함께 주면 모델이 그 경계를 다시 정할 수 있습니다. 설계 단계에서 '판정만 주면 될 텐데 원값까지 넣는 게 중복 아닌가' 를 실제로 고민했는데 원값을 넣은 쪽이 맞았습니다. 다음 노선 설계에서도 규칙 출력은 압축 전 형태로 넘깁니다. 원-핫-서수 17 열은 기여가 작지만 v6 재현 lock 안쪽이라 이번 판에서는 빼지 않습니다.

## 7. 실험 4 — 농도 피쳐 기여

**결과:** 농도 쪽이 규칙 원값보다 높음

규칙 원값 ③ 36.8%(눈) 보다 농도 쪽 ④+⑤ 가 44.0% 로 오히려 높습니다(피부 44.7%). 개별로는 f\_max\_pct 8.1%, f\_pct\_active+f\_pct\_active\_presumed 15.2%(값이 완전히 같은 두 열의 합), f\_pct\_unknown 5.2% 입니다.

규칙이 판정을 못 낸 제형에서도 '제일 많이 든 성분이 몇 %인가' 만으로 모델이 상당히 좋은 성능을 나타냅니다.

( cf. 커버리지 0.75-1.00 에서는 규칙 단독으로도 눈 0.516 · 피부 0.379 가 나옵니다. 농도 피쳐는 규칙을 대체하는 게 아니라 규칙이 비는 구간을 메우고 있습니다. )

**문제:** 역할 추정이 정확하지 않음

역할은 성분명 정규식으로 찍고, 못 찍은 것 중 농도 1 위만 active\_presumed 로 올립니다. 그 결과 성분행 5,287 개 중 3,153 개(59.6%)가 여전히 역할 미상이고 그 농도가 f\_pct\_unknown 한 열에 묻혀 들어갑니다. 죽은 열이면 넘어갈 문제인데 중요도 눈 5.2% · 피부 5.0% 로 상위권입니다. 모델이 '이름을 규칙으로 못 읽은 성분의 질량' 을 유용한 신호로 쓰고 있는 것이고, 역할 정규식 확장이 개선 후보가 되는 근거입니다.

## 8. 확인된 설계 결함 (수정 완료)

42 열을 전수로 검수하며 확인한 결함입니다. (lib\_model.py 와 input\_dataset\_v6.xlsx)

- **1. 완전 중복 4 쌍.** ct\_eye\_ord=f\_ct\_eye\_ord 와 skin·sens 3 쌍, 그리고 f\_pct\_active=f\_pct\_active\_presumed. 실효 열 수는 38 입니다. 성능에는 영향이 없지만 중요도가 반씩 쪼개져 표를 오독하게 만듭니다.
- **2. 감작 CT 열 7 개 잔존.** f\_ct\_sens\_\* 합이 눈 14.2% · 피부 18.2% 입니다. 감작은 학습 라벨에서 뺐지만 이 열들은 가산 디스크립터라 피쳐로 남았고 v6 재현 lock 때문에 뺄 수도 없습니다. 그런데 실제로 피부 예측의 5 분의 1 을 떠받치고 있습니다. 감작은 구분 1 만 나와서 \_s2 가 없으므로 8 열이 아니라 7 열입니다.
- **3. 죽은 열 1 개.** ct\_not\_applicable 은 98.4%가 한 값이고 중요도 0.0% 입니다. 다음 판에서 뺄 후보인데 지금은 v6 재현 lock 안쪽입니다.

- 4. 역할 추정 미상 59.6%. 성분행 3,153/5,287 이 unknown 입니다. f\_pct\_unknown 이 상위권 중요도를 갖는 원인입니다.

## 9. 다음 논의사항

### 해야할 것

- ① 농도 결측 2,121 행 확보. 가산식이 구분과 농도를 둘 다 받아야 계산되기 때문입니다.
- ② 역할 정규식 확장. 역할 미상 59.6% 가 한 열에 뭉쳐 있고 그 열이 상위권입니다(7 장).
- ③ 중복 4 쌍 · 죽은 열 정리. 성능이 아니라 표 가독성 문제입니다(8 장).

### 결정할 것

- 1. L2 단독 42 열을 대표 피쳐셋으로 고정하는 것에 동의하는지(5 장)
- 2. 그리고 원-핫-서수 17 열을 다음 판에서 뺄 것인지(6 장)