

SMILES 기반 모델 개발

AI신약학과 20251262 정채윤

1. 염, 수화물 처리 방법

SMILES가 점(.)으로 여러 조각으로 나뉘는 경우, 염이나 수화물의 짝이온을 제거하고 주요 활성 성분인 parent structure만 남기는 방식으로 처리함.

이는 Salt Stripping, Parent Structure Extraction이라고 하며, RDKit의

LargestFragmentChooser, SaltRemover 등에서도 사용되는 일반적인 구조 표준화 방법임.

ChEMBL 등의 화합물 DB에서도 염 형태와 parent compound를 구분하여 관리함.

-> 짝이온을 제거하고 활성 성분 중심으로 처리한 것은 타당한 전처리 방법으로 판단.

2. 전처리 방법별 피쳐 값 비교

서로 다른 전처리 방법이 실제로 같은 결과를 내는지 확인하기 위해 제형별 피쳐 값을 비교함. 따라서 전처리 방법은 실제로 달랐으며, 방법에 따라 분자량, 극성표면적 등의 피쳐값이 달라지는 제형이 존재함을 확인함.

비교 방법	값이 실제로 다른 제형 수
원본(F) vs 최대조각(A)	235 / 1450건 (16.2%)
원본(F) vs 원자수분기(AC_atomcount)	235 / 1450건 (16.2%)
원본(F) vs 화이트리스트분기(AC_whitelist)	235 / 1450건 (16.2%)
최대조각(A) vs 원자수분기(AC_atomcount)	50 / 1450건 (3.4%)
최대조각(A) vs 화이트리스트분기(AC_whitelist)	50 / 1450건 (3.4%)
원자수분기 vs 화이트리스트분기	22 / 1450건 (1.5%)

전처리 방법은 실제로 달랐으며, 방법에 따라 분자량, 극성표면적 등 피쳐값이 달라지는 제형이 존재함을 확인함.

표에 대한 설명

-원본(F) : 조각을 안 나눔. 점으로 나뉜 걸 그냥 통째로 하나의 분자로 보고 계산(아무 처리도 안 한 원래 방식)

-최대조각(A) : 염이든 혼합물이든 상관없이, 무조건 가장 큰 조각 하나만 남기고 나머지는 버림

-원자수분기(AC_atomcount) : 조각을 원자 개수로 "크다/작다" 판정 -> 큰 조각이 1개면(=염) 최대조각만 사용, 큰 조각이 2개 이상이면(=혼합물) 그 조각들을 평균냄

-화이트리스트분기(AC_whitelist) : 위에 원자수분기와 같이 분기하지만, "크다/작다"를 원자 개수 대신 직접 만든 62종 명단으로 판정

- 235 / 1450 << 정확히 원지 : 1450개 제품 중 이 두 계산 방식이 서로 다른 답을 낸 제품이 235개였다.

--- 1450 : 전체 제형 1675개 중, 성분이 최소 하나라도 SMILES 구조를 알 수 있는 제형만 남긴 개수(나머지 225개는 성분 SMILES가 읽히지 않아서 아예 비교 대상이 되지 못함)

--- 이 1450개 제형의 각각은 442개의 숫자로 이루어진 표를 하나씩 갖고 있음(분자량 등 19개 + 구조지문 423개)

--- 235 : 원본(F) 방식으로 만든 442개 숫자 표와, 최대조각(A) 방식으로 만든 442개 숫자 표를 제형마다 한 줄 씩 나란히 놓고 비교했을 때 442개 중 하나라도 숫자가 달랐던 제형의 개수

3. AUC가 비슷하게 나온 이유

전처리 방법에 따른 차이는 존재했지만, 영향을 받은 제형이 전체의 일부이고 하나의 제형에 여러 성분이 포함되어 있어 개별 성분의 변화가 전체 피쳐 값에 희석될 수 있음.

-> 처리가 비슷했던 게 아니라, 처리는 실제로 달랐는데 해당 데이터셋에서는 그 차이가 전체 AUC에 크게 영향을 미치지 않은 것으로 보임.

4. 실제로 하나를 해보았을 때 예시

Cancer_PID_13에서 네피나비르 메실산염은 점(.)으로 여러 조각 나뉘어 있음.

원본(F)은 메실산 짝이온까지 포함하여 계산하고, 최대조각(A)은 짝이온을 제거하고 활성 성분만 계산함. 그 결과 제형의 평균 분자량이 386.8->354.8로 달라졌으며, 이를 통해 전처리 방법에 따라 실제 피쳐 값이 달라지는 것을 확인함.

SMILES 기반 모델 개발 및 학습

1. 모델이란

모델이란 입력을 넣으면 그에 대한 답을 출력하는 프로그램이라고 볼 수 있음.

이번 프로젝트에서 모델의 입력은 하나의 농약 제품(제형)이며, 해당 제품에 포함된 성분들의 분자구조식인 SMILES를 사용함. 출력은 해당 제품이 눈 또는 피부에 자극성을 가지는지에 대한 판정임. 따라서 eye 모델과 skin 모델을 각각 하나씩 구축하여 성분의 분자구조만을 바탕으로 눈 자극성 또는 피부 자극성을 예측하도록 함.

이번 모델은 Random Forest 알고리즘을 이용하여 학습함. 최종적으로 성분의 위험정보, 농도, 제형 물성 등을 사용하지 않고 성분의 분자구조만을 이용하여 해당 농약 제품의 눈·피부 자극성을 예측하는 두 개의 모델(eye/skin)을 구축하는 것을 목표로 함.

2. 현재 구축한 모델의 전체적인 흐름

성분 이름 → SMILES 확보 → 분자구조 특징 추출 → AI 모델 → eye/skin 분류

성분의 SMILES를 그대로 AI 모델에 입력하는 것이 아니라, SMILES로 표현된 분자구조에서 여러 가지 구조적 특징을 추출함. 추출한 특징을 숫자 및 지문 형태의 feature로 변환한 후 Random Forest 모델에 입력하여 해당 제품의 눈 또는 피부 자극성 여부를 예측함.

위험정보, 농도, 제형, 물성 등의 정보를 사용하지 않고 성분의 분자구조에서 얻은 정보만 사용함.

3. Feature란

Feature는 성분의 SMILES를 구조적 특징을 나타내는 숫자 또는 지문 형태의 데이터로 변환한 값임.

예를 들어 SMILES가 CCO라고 할 때, 이 문자열 자체를 AI 모델에 입력하는 것이 아니라 분자구조를 분석하여 분자량, 원자의 개수, 고리 구조의 개수, 분자의 극성, 특정 구조 패턴의 존재 여부 등의 정보를 숫자 형태로 변환함.

이처럼 분자구조를 AI가 학습할 수 있는 숫자 형태로 변환한 값이 feature임.

이번 프로젝트에서는 저장소에 미리 계산되어 있는 값을 사용하는 것이 아니라 원본 ingredient.smiles를 이용하여 구조 feature를 직접 계산함.

4. 442개의 Feature가 나온 이유

이번 SMILES 모델에서는 총 442개의 feature를 사용함.

크게 세 가지 종류의 구조 정보로 구성됨.

1) RDKit 구조기술자 19개

분자의 전체적인 특성을 숫자로 표현한 값임.

대표적으로 MolWt, TPSA, MolLogP, RingCount 등이 포함됨.

MolWt는 분자량을 나타내며, TPSA는 분자의 극성과 관련된 지표임. MolLogP는 분자의 지용성·친유성과 관련된 지표이고, RingCount는 분자 안에 고리 구조가 몇 개 있는지를 나타냄.

즉, RDKit 구조기술자는 분자가 전체적으로 어떤 특성을 가지고 있는지를 숫자로 표현하는 것이라고 볼 수 있음. 총 19개의 구조기술자를 사용함.

2) MACCS Keys 167개

MACCS Keys는 분자 안에 특정한 구조 패턴이 존재하는지를 확인하는 방법임.

총 167개의 미리 정의된 구조 패턴을 확인함. 특정 작용기가 있는지, 특정 원자 배열이 있는지 등의 구조적 특징을 확인하고 해당 구조가 존재하면 1, 존재하지 않으면 0으로 표현함.

따라서 하나의 SMILES에서 167개의 0/1 형태의 구조 정보가 생성됨.

3) Morgan Fingerprint 256개

Morgan Fingerprint는 분자의 각 원자를 중심으로 주변의 구조 환경을 확인하는 방법임.

이번 모델에서는 radius=2를 사용하여 각 원자 주변의 구조적 환경을 확인하고, 해당 구조를 해시하여 256개의 fingerprint로 표현함.

결과적으로 각각의 feature가 0 또는 1의 형태로 표현됨. 특정 구조 환경이 존재하면 1, 존재하지 않으면 0으로 나타냄.

총 feature 수

RDKit 구조기술자 19개 + MACCS Keys 167개 + Morgan Fingerprint 256개 = 총 442개

즉, 하나의 SMILES를 입력하면 최종적으로 442개의 숫자 또는 구조 정보로 변환됨.

5. 442개의 Feature를 가지고 AI가 하는 일

SMILES 입력

→ RDKit 계산: 19개 구조기술자

→ MACCS Keys: 167개 구조 패턴

→ Morgan Fingerprint: 256개 구조 정보

→ 총 442개 feature 생성

→ Random Forest 모델에 입력

→ 눈 자극성 있음/없음 또는 피부 자극성 있음/없음 예측

모델은 SMILES 문자열 자체를 외우는 것이 아니라 SMILES에서 추출된 442개의 구조적 특징을 바탕으로 자극성 여부를 학습함.

6. 결측값 처리

SMILES로부터 특정 feature를 계산할 수 없는 경우 해당 값을 NaN으로 처리함.

NaN은 값이 없다는 의미이며, 결측값을 임의로 0이나 평균값으로 대체하지 않음.

또한 성분 SMILES가 전부 파싱되지 않은 제형도 데이터에서 삭제하지 않고 행 자체는 유지함. 다만 구조 정보를 전혀 확보하지 못한 제형은 `structure_coverage=0`으로 표시하고 모델 성능 평가에서는 제외함.

7. Structure Coverage란

Structure Coverage는 하나의 제품에 포함된 성분 중 SMILES를 통해 분자구조 정보를 확보할 수 있었던 성분의 비율을 의미함.

예를 들어 하나의 제품에 성분이 10개 들어 있는데 그중 8개의 성분에서 SMILES를 확보할 수 있었다면 $8/10 = 80\%$ 이므로 해당 제품의 structure coverage는 80%가 됨.

`structure_coverage=0`이라면 해당 제형에 포함된 성분에서 SMILES를 통해 구조 정보를 전혀 확보하지 못했다는 의미임.

이러한 제형도 데이터에서 삭제하지 않고 유지하되 모델 성능을 평가할 때는 제외함. 전체 5,287개 성분 중 SMILES 파싱에 성공한 성분은 3,580개로 약 67.7%였음. 나머지 약 32.3%는 SMILES 구조 정보가 확보되지 않음.

8. SMILES에 점(.)이 포함된 경우

SMILES를 처리하는 과정에서 .이 포함되어 여러 개의 조각으로 나뉘는 경우가 있었음.
ex) [Na+].O=C([O-])c1ccccc1과 같이 표현될 수 있음.

여기서 .은 서로 연결된 하나의 분자가 아니라 서로 분리된 여러 개의 분자 조각이 존재한다는 것을 의미함.

전체 5,287개 성분 중 SMILES 파싱에 성공한 3,580개를 확인한 결과, 이 중 **469건에서 .으로 구분되는 다중조각 SMILES가 확인되었으며 약 13.1%에 해당함.**

9. .이 있다고 해서 모두 혼합물은 아님

SMILES에 .이 포함되어 있다고 해서 모두 서로 다른 물질을 단순히 섞어 놓은 진짜 혼합물인 것은 아님.

크게 두 가지 경우로 구분할 수 있음.

첫 번째는 염·수화물

하나의 물질이지만 SMILES에서는 양이온, 음이온 또는 물 분자 등이 서로 분리된 조각으로 표현될 수 있음.

두 번째는 진짜 혼합물

실제로 서로 다른 물질들이 함께 존재하는 경우임.

따라서 .이 포함된 모든 SMILES를 동일한 방식으로 처리하지 않고 두 경우를 구분하여 처리함.

10. 염·수화물과 혼합물의 구분 방법

이번 모델에서는 대이온 화이트리스트(AC_whitelist) 62종을 이용하여 다중조각 SMILES를 구분함.

분리된 조각 중 특정 조각이 염을 구성하는 대표적인 대이온에 해당하는지를 데이터 기반으로 판단함.

그 결과 **염·수화물 229건, 진짜 혼합물 92건으로 구분하여 처리함.**

11. 염·수화물 처리 방법

염이나 수화물처럼 화학적으로 하나의 물질로 판단되는 경우에는 여러 조각 중 가장 큰 조각을 대표 구조로 사용함.

이는 작은 조각인 대이온이나 물 분자 등이 해당 물질의 주된 분자구조를 대표한다고 보기 어렵기 때문임.

예를 들어 [Na+]와 같은 작은 조각보다 실제 유기분자의 구조가 해당 성분의 구조적

특징을 더 잘 나타내므로 가장 큰 조각을 기준으로 구조 feature를 계산함.

12. 진짜 혼합물 처리 방법

서로 다른 물질이 실제로 섞여 있는 진짜 혼합물의 경우에는 각 조각의 feature를 각각 계산한 뒤 **평균값**을 사용함.

예를 들어 혼합물이 A+B+C로 구성되어 있다면 A의 feature, B의 feature, C의 feature를 각각 계산한 후 각 feature별로 평균을 계산함.

이렇게 계산한 평균값을 혼합물의 최종 feature로 사용함. 따라서 혼합물도 최종적으로 442개의 feature로 표현할 수 있도록 처리함.

13. 모델 학습에 사용한 라벨

라벨(y)은 AI가 예측해야 하는 정답을 의미함.

이번 모델에서는 자극성 여부를 기준으로 라벨을 설정함.

1 = 자극성 있음(양성)

0 = 자극성 없음(음성)

이러한 정답 데이터를 이용하여 **Random Forest**가 분자구조와 자극성 여부 사이의 관계를 학습하도록 함.

14. Eye 데이터

Eye 모델에 사용된 데이터는 총 1,044건임.

양성은 386건, 음성은 658건임.

양성 비율은 $386/1,044 \approx 37.0\%$ 이며, 자료에서는 **유병률 0.370**으로 표시함.

15. Skin 데이터

Skin 모델에 사용된 데이터는 총 1,059건임.

양성은 356건, 음성은 703건임.

양성 비율은 $356/1,059 \approx 33.6\%$ 이며, 자료에서는 **유병률 0.336**으로 표시함.

16. 사용한 AI 모델: Random Forest

이번 프로젝트에서는 RandomForestClassifier, 즉 Random Forest라는 머신러닝 알고리즘을 사용함.

Random Forest는 여러 개의 의사결정나무(Decision Tree)를 만든 다음 각각의 결과를 종합하여 최종 예측을 수행하는 방법임.

이번 프로젝트에서는 팀의 공통 모델 규약에 따라 다음과 같은 설정을 사용함.

n_estimators=300 : 의사결정나무를 300개 만들어 학습한다는 의미임.

class_weight="balanced" : 양성과 음성 데이터의 개수가 서로 다르기 때문에 한쪽 클래스가 학습 과정에서 상대적으로 무시되지 않도록 클래스별 가중치를 균형 있게 조정하는 설정임.

min_samples_leaf=2 : 하나의 의사결정나무에서 최종적인 잎(leaf)에 들어갈 수 있는 최소 샘플 수를 2개로 설정한 것임.

위의 Random Forest 설정은 팀 공통 규약에 따라 사용한 것이며 모델에서 동일하게 적용함. 이를 통해 모델 자체의 차이가 아니라 입력 정보의 차이를 비교할 수 있도록 함.

17. 모델 학습 및 검증 방법

모델의 성능을 한 번의 데이터 분할만으로 평가하지 않고 **StratifiedGroupKFold 5-fold** 교차검증을 사용함.

데이터를 여러 그룹으로 나누어 일부는 학습에 사용하고 나머지는 검증에 사용하는 과정을 반복하여 모델의 성능을 평가함.

또한 5개의 seed를 사용하여 반복적으로 평가하였으며, 팀에서 공통으로 정한 fold를 사용함.

18. 임계값(Threshold, τ) 설정

Random Forest 모델은 각 데이터에 대해 양성일 가능성을 확률 형태로 계산할 수 있음.

따라서 최종적으로 양성과 음성을 구분하기 위해 어느 확률 이상을 양성으로 판단할 것인지에 대한 **기준값**이 필요함. 이 **기준값**을 **임계값(Threshold, τ)**이라고 함.

이번 프로젝트에서는 학습 데이터 내부에서 추가적인 3-fold 과정을 이용하여 Youden's J가 최대가 되는 임계값을 결정하고, 결정된 임계값을 해당 검증 데이터에 적용함.

19. 모델 성능 결과

SMILES 다중조각을 대이온 화이트리스트 기준으로 처리한 AC_whitelist 모델의 성능은 다음과 같음.

ROC-AUC (pooled)

Eye: 0.6935

Skin: 0.7294

ROC-AUC (누출보정)

Eye: 0.6599

Skin: 0.7063

MCC

Eye: 0.3008

Skin: 0.3373

Balanced Accuracy

Eye: 0.6561

Skin: 0.6786

Recall

Eye: 0.6157

Skin: 0.6279

Specificity

Eye: 0.6966

Skin: 0.7293

Precision

Eye: 0.5054

Skin: 0.4947

20. ROC-AUC란

ROC-AUC는 모델이 양성과 음성을 얼마나 잘 구분하는지를 나타내는 지표임.

일반적으로 0.5에 가까우면 무작위 분류에 가까운 수준이고, 1에 가까울수록 양성과 음성을 잘 구분하는 것으로 볼 수 있음.

이번 모델의 누출보정 ROC-AUC는 Eye 0.6599, Skin 0.7063으로 나타남.

21. 누출보정이 필요한 이유

Pooled ROC-AUC의 일부 성능이 실제 화학적 예측 능력뿐만 아니라 라벨 출처의 차이를 구분하는 정보에서 발생했을 가능성이 확인됨.

따라서 라벨 출처에 따른 영향을 일부 보정하여 누출보정 ROC-AUC를 별도로 확인함.

누출보정 ROC-AUC는 Eye 0.6599, Skin 0.7063으로 나타남.

자료에서 설정한 성능 기준은 0.70 이상이며, 누출보정 값 기준으로 Eye는 기준에 미달하고 Skin은 기준을 달성함.

22. Structure Coverage 분석 결과

전체 5,287개 성분 중 SMILES 파싱에 성공한 성분은 3,580개로 약 67.7%였음.

따라서 약 32.3%의 성분은 SMILES를 통한 구조 정보가 확보되지 않은 상태였음.

구조 정보가 전혀 확보되지 않은 제형은 Eye 125건(12%), Skin 163건(15%)이었음.

반면 성분의 75% 이상에서 구조를 확인할 수 있었던 제형은 Eye 553건(53%), Skin 536건(51%)이었음.

따라서 향후 SMILES를 추가적으로 확보할 경우 구조 정보의 커버리지를 높이고 모델 성능을 보강할 여지가 있음.

23. 양성·음성 그룹의 구조적 특징 비교

양성 제형과 음성 제형에 포함된 성분들의 RDKit 구조기술자 19개를 비교함.

분석 결과 양성 제형은 음성 제형에 비해 대체로 분자량, 헤테로원자 수, 고리 개수, TPSA, 원자가전자 수 등이 더 작은 경향을 보였음.

즉, 이번 데이터에서는 상대적으로 작고 단순한 분자 구조를 가진 성분이 자극성 양성 제형과 연관되는 경향이 관찰됨.

다만 대부분의 지표에서 양성과 음성의 차이는 |z-score| 0.1~0.4 수준으로 나타났기 때문에 특정한 하나의 구조기술자만으로 자극성을 강하게 구분하기는 어려웠음.

따라서 모델은 하나의 feature만 사용하는 것이 아니라 여러 feature를 조합하여 자극성 여부를 학습함.

24. Feature Importance 분석

Random Forest의 Gini importance를 이용하여 어떤 feature가 모델의 예측에 중요하게 사용되었는지 확인함.

분석 결과 상위 20개의 feature가 모두 MACCS 또는 Morgan fingerprint로 나타났음.

반면 RDKit의 연속형 구조기술자 19개는 상위 20개에 포함되지 않았음.

이는 이번 SMILES 모델에서는 단순히 분자의 크기나 극성 등의 연속적인 수치보다 분자 안에 특정한 구조적 패턴이 존재하는지가 더 강한 판별 신호로 활용되었음을 의미함.

즉, 이번 모델에서는 "분자가 얼마나 큰가"와 같은 정보보다 "분자 안에 어떤 구조가 존재하는가"와 같은 구조 fingerprint 정보가 더 중요하게 사용된 것으로 볼 수 있음.

25. 데이터 품질 및 한계

첫째, 전체 성분 중 32.3%에서 SMILES 구조 정보가 확보되지 않았음. 따라서 모든 성분에 대해 분자구조 기반 feature를 충분히 활용할 수 없었다는 한계가 있음.

둘째, 다중조각 SMILES를 처리하는 과정에서 sanitizeFragments 관련 구현 오류가 발견되었으며 수정함.

셋째, 누출보정 AUC는 라벨 출처에 대한 한 가지 층만 보정한 값이므로 모든 종류의 데이터 편향을 제거한 값은 아님. 또한 일부 세부 층은 표본 수가 적기 때문에 결과 해석에 주의가 필요함.

26. 최종 정리

이번 프로젝트에서는 농약 제품의 위험정보, 농도, 제형 물성 등을 사용하지 않고 성분의 분자구조인 SMILES만을 이용하여 눈 및 피부 자극성을 예측하는 Random Forest 기반 모델을 구축함.

성분의 SMILES는 RDKit 구조기술자 19개, MACCS Keys 167개, Morgan Fingerprint 256개로 변환하여 총 442개의 feature로 구성함. 또한 SMILES에 .이 포함된 다중조각 성분은 대이온 화이트리스트를 이용하여 염·수화물과 진짜 혼합물을 구분하고 각각 다른 방식으로 처리함.

최종 모델의 누출보정 ROC-AUC는 Eye 0.6599, Skin 0.7063으로 나타났으며, Feature Importance 분석에서는 MACCS 및 Morgan fingerprint가 주요한 판별 정보로 사용된 것으로 확인됨.

또한 전체 5,287개 성분 중 SMILES 파싱 성공률은 67.7%로 나타났으며, 향후 구조 정보를 추가적으로 확보할 경우 모델의 구조 정보 커버리지와 성능을 보강할 가능성이 있음.

Q&A

Q1. 결측값처리랑 관련된 질문

성분 SMILES가 전부 파싱되지 않은 제형도 데이터에서 삭제하지 않고 행 자체는 유지한다. 다만 구조가 정보를 전혀 확보하지 못한 제형은 `structure_coverage=0`으로 표시하고 모델 성능 평가에서는 제외함.

이라고 했잖아. 왜 행 자체는 유지하는지 그리고 구조가 전혀 확보되지 못한 애들은 0으로 하는건데 그러면 만약에 하나의 성분에 10개의 성분이 있어. 근데 5개는 알겠어. 그래서 `structure_coverage=50%`야. 그러면 완전히 이 제품에 대해서 아는게 아닌데 모델 성능 평가에서 포함해도 되는거야?

A. 행 자체를 삭제하지 않는 이유는 팀 전체가 동일한 1,675개 제품 목록을 기준으로 교차검증 폴드를 나누어 사용하고 있기 때문임. 임의로 일부 제품을 삭제하면 데이터 행 수와 공통 폴드 기준이 달라져 다른 팀원들의 결과와 비교하기 어려워짐. 따라서 구조 정보를 확보하지 못한 제품도 행 자체는 유지하고, `structure_coverage=0`으로 표시하여 해당 제품이 구조 정보 부족으로 분석에서 제외되었음을 추적할 수 있도록 함.

다만 질문한 것처럼 일부 성분만 파싱된 경우에는 문제가 있음. 예를 들어 하나의 제형에 10개의 성분이 있는데 그중 5개만 파싱된다면 `structure_coverage`는 50%가 됨. 현재 모델은 `structure_coverage`가 0%인 경우만 성능 평가에서 제외하고, 1% 이상이면 모두 포함하는 방식으로 처리하고 있음.

실제로 커버리지별 성능을 확인한 결과, `structure_coverage`가 낮을수록 특히 25% 미만에서 성능이 눈에 띄게 낮아지는 경향이 확인됨. 따라서 현재 보고서의 전체 성능에는 저커버리지 데이터도 포함되어 있으며, 구조 정보가 충분한 데이터에서의 실제 성능보다 낮게 나타날 가능성이 있음.

따라서 50%처럼 일부 구조 정보만 확보된 제형을 모델 성능 평가에 포함하는 것이 적절한지에 대해서는 추가적인 검토가 필요함. 향후에는 일정 수준 이상의 `structure_coverage`를 기준으로 데이터를 나누어 성능을 비교하는 방식 등을 고려할 수 있음.

성분 확보율	eye AUC	eye MCC	skin AUC	skin MCC
0~25%	0.531 (거의 랜덤)	0.053	0.571	0.218
25~50%	0.676	0.304	0.595	0.071
50~75%	0.728	0.418	0.771	0.370
75~100%	0.680	0.334	0.739	0.360

Q2. `structure_coverage`랑 관련된 질문

이러한 제형도 데이터에서 삭제하지 않고 유지하되 모델 성능을 평가할 때는 제외함.

전체 5,287개 성분 중 SMILES 파싱에 성공한 성분은 3,580개로 약 67.7%였음. 나머지 약 32.3%는 SMILES 구조 정보가 확보되지 않음. 라고 했는데 그럼 32.3%는 structure_coverage가 0이라는거야 아니면 100이 아니라는거야?
아니요. 32.3%와 structure_coverage는 서로 다른 기준임.

32.3%는 전체 5,287개의 성분(ingredient) 중 SMILES 파싱에 실패하여 구조 정보를 확보하지 못한 성분의 비율임. 반면 structure_coverage는 제품(제형) 하나를 기준으로, 해당 제품에 포함된 성분 중 몇 %의 구조 정보를 확보했는지를 나타내는 값임.

예를 들어 성분이 10개인 제품에서 7개의 SMILES를 확보하고 3개가 파싱되지 않았다면, 전체 성분 기준으로는 32.3%의 파싱 실패 데이터에 포함되지만 해당 제품의 structure_coverage는 70%가 됨.

따라서 전체 성분의 32.3%가 SMILES 구조 정보를 확보하지 못했다고 해서 모든 제품의 structure_coverage가 67.7%이거나 0%가 되는 것은 아님. 제품마다 확보된 성분의 비율이 다르기 때문임.

실제로 structure_coverage=0인 제품은 eye 기준 1,044개 중 125개(12%), skin 기준 1,059개 중 163개(15%)임. 즉, 32.3%는 성분 단위의 SMILES 파싱 실패율이고, structure_coverage=0은 제품 단위에서 구조 정보를 하나도 확보하지 못한 경우를 의미함.

Q3. 임계값 설정과 관련된 질문

이번 프로젝트에서는 학습 데이터 내부에서 추가적인 3-fold 과정을 이용하여 Youden's J가 최대가 되는 임계값을 결정하고, 결정된 임계값을 해당 검증 데이터에 적용함. 이라고 했는데 이게 무슨 말이야? 3-fold는 뭐고 Youden's J는 뭐야?

모델은 제형이 위험할 확률을 0~1 사이의 숫자로 출력하기 때문에, 이 값을 실제로 양성(위험)과 음성(비위험)으로 나누기 위한 기준인 임계값(threshold)을 정해야 함. 단순히 0.5를 기준으로 나누는 것보다 데이터에 맞는 임계값을 정하는 것이 필요함.

3-fold는 임계값을 정하기 위해 학습 데이터 안에서 다시 데이터를 3개로 나누어 검증하는 과정임. 이때 최종 검증 데이터는 임계값을 결정하는 과정에서 사용하지 않음. 학습 데이터를 3개로 나눈 뒤, 2개 부분으로 학습하고 나머지 1개 부분으로 예측하는 과정을 3번 반복함. 이를 통해 학습 데이터 전체에 대해 실제 검증과 비슷한 예측값을 만들고, 이 예측값을 이용해 적절한 임계값을 결정함. 따라서 최종 검증 데이터를 미리 확인하지 않고 임계값을 정할 수 있음.

Youden's J는 여러 임계값 중 어떤 값을 사용할지 결정하기 위한 기준임. 계산식은 다음과 같음.

Youden's J = 재현율(Recall) + 특이도(Specificity) - 1

여기서 재현율은 실제 양성인 제형을 양성으로 판단하는 비율이고, 특이도는 실제 음성인 제형을 음성으로 판단하는 비율임. Youden's J가 가장 커지는 지점의 임계값을 선택하여 양성과 음성을 구분함.

즉, 이번 모델에서는 학습 데이터 내부에서 3-fold 검증을 통해 예측값을 만든 후, Youden's J가 가장 큰 지점을 임계값으로 결정하고, 이렇게 정해진 임계값을 최종 검증 데이터에 적용하는 방식으로 진행함.

Q4. 모델 성능 결과와 관련된 질문

ROC-AUC (pooled), ROC-AUC (누출보정), MCC, Balanced Accuracy, Recall, Specificity, Precision 이게 뭐야?
누출보정은 뭐 어떻게 한거야?

모델 성능을 평가할 때 여러 가지 지표를 사용함. 각각 보는 기준이 조금씩 다름.

Recall(재현율)은 실제로 위험한 제형 중에서 모델이 위험하다고 correctly 판단한 비율임.

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

Specificity(특이도)는 실제로 안전한 제형 중에서 모델이 안전하다고 판단한 비율임.

$$\text{Specificity} = \text{TN} / (\text{TN} + \text{FP})$$

Precision(정밀도)은 모델이 위험하다고 예측한 제형 중에서 실제로 위험한 제형의 비율임.

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

Balanced Accuracy는 Recall과 Specificity의 평균임.

$$\text{Balanced Accuracy} = (\text{Recall} + \text{Specificity}) / 2$$

양성·음성 데이터의 수가 서로 다른 경우에도 두 그룹의 분류 성능을 각각 반영하기 위해 사용함.

MCC(Matthews Correlation Coefficient)는 TP, TN, FP, FN을 모두 고려하여 모델의 분류 성능을 하나의 값으로 나타내는 지표임. 값은 -1에서 1 사이이며, 1에 가까울수록 예측이 잘 된 것이고 0에 가까우면 랜덤한 예측에 가까움. 데이터의 양성·음성 비율이 불균형한 경우에도 사용할 수 있음.

ROC-AUC는 특정 임계값 하나를 기준으로 평가하는 것이 아니라, 모델이 실제 위험한 제형에 더 높은 예측 점수를 부여하는지를 전체 임계값 범위에서 평가하는 지표임. 일반적으로 0.5는 랜덤한 수준이고 1.0에 가까울수록 분류 성능이 높음을 의미함.

Pooled와 누출보정의 차이는 데이터를 어떻게 나누어 AUC를 계산하느냐에 있음.

Pooled ROC-AUC는 모든 검증 데이터를 하나로 합친 뒤 전체 데이터에서 AUC를 계산한 값임.

반면 누출보정은 라벨의 출처에 따라 데이터를 NTP 실측 데이터, SDS 문구 데이터, SDS 11절 데이터의 3개 그룹으로 나누고, 각 그룹 내부에서 AUC를 계산한 후 그룹의 데이터 수를 기준으로 가중평균하는 방식임.

이러한 누출보정을 하는 이유는 각 라벨 출처마다 위험 제형의 비율이 크게 다르기 때문임. 예를 들어 한 그룹의 위험 제형 비율이 약 0.19이고 다른 그룹은 약 0.75라면, 모델이 실제 화학 구조의 차이를 학습한 것이 아니라 데이터가 어느 출처에서 왔는지를 간접적으로 구분하는 것만으로도 성능이 높게 나타날 가능성이 있음.

따라서 각 라벨 출처 그룹 내부에서 AUC를 계산하면 이러한 데이터 출처에 따른 차이의 영향을 줄이고, 구조 정보 자체가 분류에 어느 정도 기여하는지를 보다 엄격하게 확인할 수 있음.

즉, Pooled ROC-AUC는 전체 데이터를 한꺼번에 평가한 결과이고, 누출보정 ROC-AUC는 라벨 출처에 따른 차이로 인해 성능이 부풀려지는 것을 줄이기 위해 그룹별로 계산한 결과임.

Q5. Feature Importance 분석과 관련된 질문

Random Forest의 Gini importance를 이용하여 어떤 feature가 모델의 예측에 중요하게 사용되었는지 확인함. 이라고 되어 있는데 Gini importance 이게 뭐야?

Random Forest는 여러 개의 Decision Tree(결정 트리)를 만들어 각각의 결과를 종합하여 최종적으로 분류하는 모델임. 이번 모델에서는 300개의 트리를 사용함.

Decision Tree에서는 특정 feature를 기준으로 데이터를 계속 나누면서 위험/안전 제형을 구분함. 예를 들어 "TPSA가 특정 값보다 큰가?"와 같은 기준을 사용하여 데이터를 나누는 방식임.

Gini importance는 이러한 과정에서 각 feature가 데이터를 얼마나 잘 구분하는 데 기여했는지를 나타내는 지표임. 특정 feature를 사용했을 때 위험과 안전 데이터가 잘 분리될수록 해당 feature의 중요도가 높게 나타남. 반대로 해당 feature로 데이터를 나누어도 위험과 안전이 잘 구분되지 않으면 중요도가 낮게 나타남.

Random Forest에서는 여러 개의 Decision Tree에서 계산된 feature의 중요도를 종합하여 최종적인 Gini importance를 계산함.

따라서 Gini importance를 통해 모델이 여러 feature 중 어떤 feature를 분류 과정에서 상대적으로 많이 활용했는지 확인할 수 있음. 이번 분석에서는 Feature Importance를 확인하여 어떤 구조적 feature가 모델의 예측에 기여했는지를 분석함.

Q6. 데이터 품질 및 한계량 관련된 질문

둘째, 다중조각 SMILES를 처리하는 과정에서 sanitizeFragments 관련 구현 오류가 발견되었으며 수정함. 이러면 뭐 더 문제는 없다는거지?

셋째, 누출보정 AUC는 라벨 출처에 대한 한 가지 층만 보정한 값이므로 모든 종류의 데이터 편향을 제거한 값은 아님. 또한 일부 세부 층은 표본 수가 적기 때문에 결과 해석에 주의가 필요함. 이걸 뭐 어떻게 해야돼?

sanitizeFragments 관련 구현 오류를 수정했다는 것이 다른 문제가 전혀 없다는 의미는 아님.

이번 분석 과정에서 확인된 해당 오류를 수정했고, 수정 후 결과에 문제가 없는지 재확인했다는 의미임. 따라서 현재까지 확인된 해당 오류는 해결된 상태이지만, 다른 종류의 오류나 문제가 없다는 것을 의미하는 것은 아님.

누출보정 AUC의 한계는 반드시 추가로 수정해야 하는 문제라기보다는 해당 성능 수치를 해석할 때 주의해야 하는 부분임.

현재 누출보정에서는 라벨의 출처에 따른 한 가지 편향만 보정함. 따라서 특정 제조사 제품이 특정 데이터에 집중되어 있는 경우처럼 다른 종류의 데이터 편향까지 모두 제거한 것은 아님. 즉, 누출보정 AUC를 모든 편향이 제거된 완전한 모델 성능으로 볼 수는 없음.

또한 일부 세부 그룹은 표본 수가 적기 때문에 해당 그룹에서 계산된 성능 수치가 실제보다 높거나 낮게 나타날 가능성이 있음. 예를 들어 skin의 SDS 11절 문서공유 그룹은 80건으로 표본 수가 적기 때문에 해당 그룹의 AUC 0.824만으로 성능이 높다고 단정하기 어려움.

따라서 별도의 조치를 반드시 해야 한다는 의미는 아니며, 현재 결과를 해석할 때 이러한 한계가 있다는 점을 함께 고려해야 함. 향후에는 다른 종류의 데이터 편향을 추가로 확인하거나, 표본 수가 충분한 데이터에서 성능을 재평가하는 방식으로 보완할 수 있음.

Q7. 화이트리스트 관련된 질문

근데 너가 만든 화이트리스트가 잘못됐으면 어떡해?

실제로 잘못됨. 화이트리스트를 62종 → 60종으로 수정하고, 엑셀 4개를 다시 저장했습니다. 수정 내용: smiles_fragments.py의 COUNTERION_SMILES에서 과산화수소(OO)와 인산 자유산 형태($O=P(O)(O)O$)를 제거 (코드에 수정 이유·날짜 주석 남김). 인산의 이온화된 형태(인산염, 짝이온으로 쓰이는 경우)는 그대로 남겨뒀습니다 — 문제였던 건 "자유산으로서 독립 작용하는" 경우였어서요.

갱신된 파일 (연구 모델개발 최종본과 SMILES_모델개발_정채윤 양쪽에 저장):

- SMILES_다중조각_분류_전체.xlsx
- 방법1_모든경우_최대조각만사용.xlsx (변화 없음 — 화이트리스트 미사용 방법)
- 방법2_염수화물최대조각_혼합물평균_원자수기준.xlsx (변화 없음 — 원자수 기준이라 무관)

- 방법3_염수화물최대조각_혼합물평균_화이트리스트기준.xlsx (변경 됨)