

최소빈 - 완제품 모델 학습

- 파이프라인 참고 (입력/라벨 데이터 확보 등)
- 작업은 공통모델규약_배포_260914.zip 기반

★ 전반적인 구조

노선	담당	입력 정보원(X)	feature	가설
L1	완제품	SDS 선언값 (Section 9. 물성·제형코드 등)	52열	제품 문서에 적힌 물성만으로 분류를 맞출 수 있다
L2	성분	성분별 위험정보 x 농도 + 혼합물 조성	42열	GHS 혼합물 분류 규칙 + 성분 정보로 분류를 재현할 수 있다
L3	SMILES	성분 분자구조	98열	구조식만으로, 위험정보 없이 분류를 맞출 수 있다

↑ 같은 라벨을 서로 다른 정보원으로 예측 및 비교 (피처만 다름)

- (L1) 완제품 - 성분 및 분자구조 정보 없이 제품의 겉모습만 보고 예측

★ feature 준비

- feature = 제품의 물성 (판정 기준 - 공통모델규약_배포_260914.zip → 52열 채택)

↑ input_dataset_v6.xlsx에서 추출

L1 완제품 모델 피처 구성 (52열)

A-1. CIPAC 제형코드 12열 SDS 표지	A-2. 제형유형 11열 SDS 표지	B. 연속 물성 15열 SDS 9절	C-1. 물리상태 8열 SDS 9절	C-2. 용해특성 6열 SDS 9절
--	----------------------------------	---------------------------------	---------------------------------	---------------------------------

범주형 37열 (one-hot) | 연속형 15열 (결측 있음, NaN 유지)

그룹	열 수	형태	출처	내용
A-1. CIPAC 제형코드	12	범주형 (one-hot)	SDS 제품식별	EC, SC, SL, WG, WP, GR 등
A-2. 제형유형	11	범주형 (one-hot)	SDS 제품식별	유제, 액상수화제, 수화제 등
B. 연속 물성	15	연속형 (결측 포함)	SDS Section 9	PH, 밀도, 인화점, logKow 등
C-1. 물리적 상태	8	범주형 (one-hot)	SDS Section 9	liquid, solid, powder 등
C-2. 용해 특성	6	범주형 (one-hot)	SDS Section 9	miscible, soluble 등

↑ feature 구성 체크

- 결측은 NaN으로 처리 (0 또는 평균으로 대체 X)
- 더 건드릴 것이 안 보여서 바로 모델 학습으로 넘어감

★ 모델 학습

- 라벨(y)

endpoint	n	양성	음성	유병률	관할
eye	1,044	386	658	0.370	EU_CLP
skin	1,059	356	703	0.336	EU_CLP

- 성능 결과

지표	eye	skin
ROC-AUC (pooled)	0.7222 ± 0.0052	0.7174 ± 0.0087
ROC-AUC (누출보정)	0.6642 ± 0.0073	0.6605 ± 0.0109
MCC	0.3252	0.3114
Balanced Accuracy	0.6625	0.6604


Recall (재현율)	0.5819	0.6028
Specificity (특이도)	0.7432	0.7181
Precision (정밀도)	0.5731	0.5209
임계값 τ 평균 (범위)	0.467 (0.363~0.608)	0.437 (0.375~0.548)

• pooled 값의 약 26%는 화학적 예측이 아닌 라벨 출처 판별분이었다.


→ NTP와 SDS의 제품 특성이 체계적으로 달라 “어느 출처의 제품인지”를 간접적으로 구분하는 것만으로도 AUC가 올라간다. (성능 부풀림)

→ 라벨 출처 층 간 유병률 격차(문서독립 0.19 vs 문서 공유 0.75)를 보정

L1 - Pooled vs Corrected AUC



★ 성능 분석



① feature 채움률 - 연속형 50% 미만 / 범주형 100%

- 15열 전부 채워진 제형 : 0건

- 평균 기입 열 수 : 3.8/15 (제형 하나당 4개 이하)

- 전체 25,125셀 중 채워진 셀 : 25.3%

- 15열 전부 비어있는 제형 : 200건 (Section 9 자체가 파싱이 안 됨)

▶ 데이터 추가 수집 → 성능 보강 검토

#. 결측인 행도 학습에서 빠지진 않음 - “없다”는 사실 자체를 판단 근거로 학습


→ (ex) 고체 제형(GR, WP)은 인화점 측정을 안 하는 경우가 많아 NaN / 이때 해당 제형은 자극 위험도 낮은 경향이 있어 “인화점이 없다 $\approx$ 자극 위험 낮다”는 간접 정보가 됨

② 연속형 물성 중 일반적 범위를 벗어나는 값 확인

(ex) - 밀도 19.5 → SDS 원문 확인 → 실제 기재값 15-24 lb/ft³ 확인

▶ 데이터 오류 검토

(+) 참고



→ feature의 importance를 측정하였을 때, 연속형이 범주형보다 유효했음을 확인

#. importance는 RandomForest의 Gini importance(Mean Decrease in Impurity)로 산출